

채용 데이터로 다시 배우는 통계

Datathon “Exploring Bias in Hiring” 대비 개념서 + 문제집

용어는 영어 원문 그대로, 설명은 한국어로. 모든 수치는 `hiring_practice.csv` (600행)에서 직접 계산한 값입니다.

먼저 읽기: 분석 전체 흐름과 책 안내

네 권의 역할

표시	책 (파일)	역할
[흐름]	pandas 흐름으로 따라가는 통계 (pandas-stats-walkthrough)	기초: 평균·SD·정규·상관·회귀·검정을 pandas 순서대로
[응용]	채용 데이터로 다시 배우는 통계 (hiring-statistics-book)	응용: 통계 회귀, logistic, Bayesian, 공정성으로 결론 내기
[알고]	알고리즘으로 보는 pandas (algorithms-for-datathon)	도구: 빠르고 정확한 코드, 결정트리·greedy 보조 분석
[실습]	코드로 연습하는 분류 (classification-workbook)	실습: 빈칸 노트북으로 분류 모델을 직접 만들고 공정성 감사

※ 아래 표의 작은 색 주석이 “이 단계는 어느 책 몇 장”입니다. 예: [흐름 5] = 흐름 책 5장, [응용 6.9] = 응용 책 6.9절, [알고 4] = 알고리즘 책 4장. 0장 = 응용 책 앞의 “데이터 미리보기와 pandas 작동 원리”.

Datathon 분석 흐름: 데이터를 받은 순간부터 발표까지

단계	하는 일	대표 pandas 코드	해당 장
①	질문을 통계 질문으로	–	[응용 1] [흐름 1 추정·가설·검증 상자]
②	불러오고 구조 확인	read_csv, head, info	[응용 0.1–0.3] [흐름 1]
③	변수 분류 (결과 Y / 보호속성 A / 자격 X)	dtypes, value_counts	[응용 2] [흐름 1.1]
④	결측·이탈값 처리	isna, dropna, quantile	[응용 0.7, 2.4] [흐름 1.3, 2.3]
⑤	분포 요약 (중심, 퍼짐, 정규성)	describe, std, $(x-x.mean())/x.std()$	[흐름 2, 3] [응용 3.1] [알고 3 분위수]
⑥	그룹별 합격률과 신뢰구간	groupby().mean()	[응용 0.5, 3.2] [흐름 4] [알고 4 groupby 내부]
⑦	교란 변수 확인 (Simpson)	crosstab, groupby([a,b])	[응용 3.3] [흐름 12 ⑧]
⑧	가설검정 (차이가 우연인가)	proportions_ztest, chi2_contingency, ttest_ind	[흐름 5, 11, 12] [응용 5]
⑨	상관과 단순회귀	corr, pd.cut, smf.ols	[흐름 6–8] [알고 5 pd.cut]
⑩	통제 회귀와 interaction (핵심)	smf.ols("y ~ A + X"), A*B	[응용 0.8–0.9, 6] [흐름 13]
⑪	다른 방법으로 재확인	smf.logit, rng.beta, DecisionTreeClassifier	[응용 7, 8] [흐름 9 bootstrap] [알고 6, 7] [실습 6–10]
⑫	공정성 지표와 한계	rate["F"]/rate["M"], idxmin	[응용 9] [알고 8 minimax] [실습 11]
⑬	정리와 발표	–	[응용 9.2 결론 문장, 11 체크리스트] [흐름 14 요약] [알고 11]

※ 이론이 막히면: 추정량·MoM·MLE [흐름 9–10] [응용 4], 가설 세우기·검정력 [흐름 11], 코드가 느리면 [알고 1–2, 4]. 한 번에 돌려 보기: python3 algo_toolkit.py hiring_practice.csv (⑥⑦⑨⑪⑫ 요약).

6시간 읽기 계획 (읽기 편한 순서)

시간	무엇을	어디를	분
0:00	데이터와 pandas 감 잡기	[응용 0] 전체, [응용 1] 전체 지도	30
0:30	기초 통계 1: 요약과 분포	[흐름 1-3] (<code>describe</code> , 표준화, 정규근사)	50
1:20	기초 통계 2: 추정과 검정	[흐름 4-5] (신뢰구간, $z/\chi^2/t$)	40
2:00	휴식		10
2:10	기초 통계 3: 상관과 회귀	[흐름 6-8] (회귀 효과, RMSE, 잔차도)	50
3:00	검정 고르는 법	[흐름 12] 검정 도구상자 (표 + 관심 있는 카드만)	30
3:30	응용 1: 통계와 interaction	[응용 3, 6] + 각 장 끝 “pandas 코드” 직접 실행	50
4:20	휴식		10
4:30	응용 2: 재확인	[응용 7] logistic, [응용 8] Bayesian (8.4 “왜”는 꼭)	40
5:10	결론과 한계	[응용 9], [응용 11] 체크리스트, [알고 표지 결론표]	20
5:30	도구 실행과 발표 문장 연습	<code>algo_toolkit.py</code> 실행, [응용 9.2] 문장을 내 말로	30
(여유)	코드로 손에 익히기	[실습 1-12] 빈칸 노트북 (<code>classification_practice.ipynb</code>)	90

※ 건너뛰어도 되는 곳 (나중에 참고용): [흐름 9-11, 13], [응용 4, 10], [알고 1-10] 본문, 모든 연습 문제. 시간이 남으면 [흐름 15] 연습 문제 1-8번부터.

※ 각 장은 새 페이지에서 시작하고, 목차의 항목을 누르면 그 쪽으로 이동합니다.

목차 (Contents)

먼저 읽기: 분석 전체 흐름과 책 안내	2
0 데이터 미리보기와 pandas 작동 원리	5
0.1 데이터 사전	5
0.2 불러오기와 첫 10행	5
0.3 구조 확인: info()	6
0.4 행 고르기: boolean mask	6
0.5 groupby: split, apply, combine	6
0.6 crosstab: 빈도 교차표	7
0.7 결측 처리: dropna()	7
0.8 회귀 수식은 어떻게 행렬이 되나	7
0.9 결과 꺼내기	8
1 전체 지도: 데이터 테이블을 받으면 무엇을 하는가	9
2 데이터 테이블 분류하기	10
2.1 관측 단위와 변수	10
2.2 변수의 종류 (Type)	10
2.3 변수의 역할 (Role): 무엇이 중요한 데이터인가	10
2.4 결측치 (Missing data)	11
3 기술통계와 EDA: 숫자로 먼저 보기	12
3.1 기본 도구	12
3.2 우리 데이터의 숫자	12
3.3 Confounding과 Simpson's paradox	12
pandas 코드: 그룹별 합격률과 교차표	13
4 확률모형과 추정: MoM과 MLE	14
4.1 왜 확률모형이 필요한가	14
4.2 자주 쓰는 분포	14
4.3 Method of Moments (MoM)	14
4.4 Maximum Likelihood Estimation (MLE)	15
4.5 MoM vs MLE	15
5 가설검정과 신뢰구간 (Frequentist)	16
5.1 가설검정의 논리: 귀류법과 같은 구조	16
5.2 Two-proportion z -test	16
5.3 Chi-square test of independence	17
5.4 t -test: 평균 비교	17
5.5 신뢰구간 (Confidence interval)	17

5.6	검정 선택표	17
	pandas 코드: 검정과 신뢰구간	18
6	선형회귀와 OLS	19
6.1	왜 회귀가 필요한가	19
6.2	모형	19
6.3	OLS: 최소제곱 추정	19
6.4	Dummy variable: 범주형 변수 넣기	19
6.5	Linear Probability Model (LPM)	19
6.6	OLS는 MoM이기도 하다	20
6.7	회귀 계수의 검정	20
6.8	Omitted variable bias: 왜 통제가 필요한가	20
6.9	Interaction	20
	pandas 코드: 세 개의 LPM	21
7	Logistic regression과 GLM	22
7.1	아이디어: log-odds를 직선으로	22
7.2	추정: MLE	22
7.3	계수 해석: odds ratio와 한계효과	22
7.4	모형 비교: Likelihood ratio test, AIC, BIC	22
7.5	GLM: 하나의 틀	23
	pandas 코드: Logistic regression	23
8	Bayesian 통계: 왜, 어떻게	24
8.1	두 관점의 차이	24
8.2	Bayes' theorem	24
8.3	Beta-Binomial: 합격률의 Bayesian 추정	24
8.4	왜 Bayesian을 많이 쓰는가	25
8.5	Bayesian 가설 비교	25
8.6	Bayesian 회귀와 MAP	25
8.7	요약표	26
	pandas 코드: Beta-Binomial 시뮬레이션	26
9	공정성 지표와 인과의 한계	27
9.1	Fairness metrics	27
9.2	상관은 인과가 아니다	27
	pandas 코드: 공정성 지표	28
10	그 밖의 도구들	29
11	Datathon 체크리스트	30

12 연습 문제	31
13 풀이	32
부록: 전체 데이터 (600행)	35

0 데이터 미리보기와 pandas 작동 원리

이 책의 모든 숫자는 아래 표 한 장에서 나옵니다. 본문을 읽기 전에 데이터가 어떻게 생겼는지, 그리고 pandas 코드가 그 표를 어떻게 바꾸는지를 작은 예(처음 10행)로 먼저 봅니다. 전체 600행은 부록에 있습니다.

0.1 데이터 사전 (data dictionary)

열 이름	뜻	값	pandas dtype
applicant_id	지원자 번호	1-600	int64
gender	성별	"F" (313명), "M" (287명)	object (문자열)
department	지원 부서	"Engineering" (326), "Marketing" (274)	object
years_experience	경력 (년)	0-11 정수	int64
degree	최종 학위	"Bachelor" (311), "Master" (231), "PhD" (58)	object
test_score	시험 점수	29-100, 결측 18개	float64
hired	합격 여부	1 = 합격 (193명), 0 = 불합격	int64

※ test_score만 float64인 이유: 결측값 NaN은 실수형에만 들어갈 수 있어서, 정수 점수인데도 pandas가 실수로 읽습니다.

0.2 불러오기와 첫 10행

```
import pandas as pd
df = pd.read_csv("hiring_practice.csv") # CSV 파일 → DataFrame (표)
df.head(10) # 위에서 10행
```

index	applicant_id	gender	department	years_experience	degree	test_score	hired
0	1	M	Engineering	5	Bachelor	69.0	1
1	2	F	Marketing	5	Master	76.0	0
2	3	F	Marketing	4	Bachelor	73.0	0
3	4	M	Engineering	6	Master	73.0	1
4	5	F	Marketing	5	Bachelor	49.0	1
5	6	F	Marketing	4	PhD	62.0	0
6	7	F	Marketing	6	PhD	42.0	0
7	8	F	Marketing	3	Bachelor	73.0	0
8	9	M	Engineering	2	Bachelor	65.0	0
9	10	F	Marketing	3	Master	69.0	0

- **DataFrame** = 표. 각 열은 **Series** (이름 붙은 1차원 배열)이고, 모든 열이 같은 **index** (맨 왼쪽 0, 1, 2, ...)를 공유합니다.
- `df["hired"]`는 Series 하나, `df[["gender", "hired"]]`는 열 두 개짜리 DataFrame입니다 (대괄호 두 겹).
- index는 0부터, applicant_id는 1부터 시작합니다. 둘은 다른 것입니다.

0.3 구조 확인: info()

```
df.info()
RangeIndex: 600 entries, 0 to 599
#   Column                Non-Null Count  Dtype
0   applicant_id          600 non-null       int64
1   gender                 600 non-null       object
2   department             600 non-null       object
3   years_experience        600 non-null       int64
4   degree                 600 non-null       object
5   test_score             582 non-null       float64
6   hired                  600 non-null       int64
```

← 18개 절측

※ 처음 보는 데이터에서 가장 먼저 보는 것: 행 수, 열 이름, dtype, **Non-Null Count**가 행 수보다 작은 열 (= 결측 있음).

0.4 행 고르기: boolean mask

```
t = df.head(10)
mask = t["department"] == "Engineering"
t[mask]
```

행마다 True/False
True인 행만

index	0	1	2	3	4	5	6	7	8	9
mask	True	False	False	True	False	False	False	False	True	False

결과: index 0, 3, 8 (지원자 1, 4, 9) 세 행. 조건을 합칠 때는 & (and), | (or)를 쓰고 각 조건을 괄호로 감쌉니다: `t[(t.gender=="F") & (t.hired==1)]` → 지원자 5 한 명.

0.5 groupby: split → apply → combine

이 책에서 가장 많이 쓰는 한 줄입니다.

```
t.groupby("gender")["hired"].agg(["sum", "count", "mean"])
```

① **Split**: gender 값에 따라 행을 나눕니다.

그룹	해당 지원자	hired 값
F	2, 3, 5, 6, 7, 8, 10	0, 0, 1, 0, 0, 0, 0
M	1, 4, 9	1, 1, 0

② **Apply**: 그룹마다 sum, count, mean을 계산합니다. ③ **Combine**: 결과를 그룹 이름을 index로 하는 표로 합칩니다.

gender	sum	count	mean
F	1	7	0.143
M	2	3	0.667

※ hired가 0/1이므로 sum = 합격자 수, count = 지원자 수, mean = 합격률. 전체 600행으로 하면 F: $68/313 = 0.217$, M: $125/287 = 0.436$ (§3.2).

※ 그룹 기준을 여러 개 주면 (groupby(["department", "gender"])) 모든 조합별로 나눕니다 (§3.3의 교차표).

0.6 crosstab: 빈도 교차표

```
pd.crosstab(t["gender"], t["hired"]) # 행 = gender, 열 = hired, 칸 = 사람 수
```

gender \ hired	0	1
F	6	1
M	1	2

※ 비율로 보려면 `normalize="index"` (행 합이 1). χ^2 검정 (§5.3)은 이 표를 그대로 입력으로 받습니다.

0.7 결측 처리: dropna()

```
df[df["test_score"].isna()] # 결측 행 보기: 지원자 38, 94, 112, 136, 147, ... (18명)
d = df.dropna() # 결측이 하나라도 있는 행 제거 → 582행
```

※ `dropna()`는 원본 `df`를 바꾸지 않고 새 표를 돌려줍니다. 그래서 `d = ...`로 받아야 합니다. 회귀 (§6-7)는 이 `d`를 씁니다.

0.8 회귀 수식은 어떻게 행렬이 되나

```
import statsmodels.formula.api as smf
m = smf.ols("hired ~ C(gender) + C(department) + C(degree) + test_score +
years_experience", data=d)
```

`statsmodels`는 수식 문자열을 읽어 §6.2의 행렬 X 를 만듭니다. 처음 10행에 대해 만들어지는 X :

지원자	Intercept	[T.M]	[T.Marketing]	[T.Master]	[T.PhD]	test_score	years_exp
1	1	1	0	0	0	69	5
2	1	0	1	1	0	76	5
3	1	0	1	0	0	73	4
4	1	1	0	1	0	73	6
5	1	0	1	0	0	49	5
6	1	0	1	0	1	62	4
7	1	0	1	0	1	42	6
8	1	0	1	0	0	73	3
9	1	1	0	0	0	65	2
10	1	0	1	1	0	69	3

- `C(gender)` → [T.M] 한 열: 남성 1, 여성 0. 기준 범주(F)는 열이 없습니다 (알파벳 순 첫 번째가 기준).
- `C(degree)` → Master, PhD 두 열. Bachelor는 둘 다 0 (§6.4 dummy variable).
- 숫자 열은 그대로 들어갑니다. `Intercept`는 자동으로 추가되는 1의 열.
- 그다음 $\hat{\beta} = (X^T X)^{-1} X^T y$ 를 계산합니다 (§6.3). `.fit()`이 이 단계입니다.

※ 이 10행만으로는 회귀를 할 수 없습니다: [T.M]과 [T.Marketing] 열이 정확히 반대(남성 = Engineering, 여성 = Marketing)라서, 두 열과 Intercept가 일차종속 ($[T.M] + [T.Marketing] = \text{Intercept}$)입니다. 그러면 $X^T X$ 의 역행렬이 없습니다 (**perfect multicollinearity**). 600행 전체에서는 Marketing 남성, Engineering 여성이 있어서 풀립니다. 성별과 부서가 강하게 얽혀 있다는 것 (§3.3)의 극단적인 형태입니다.

0.9 결과 꺼내기

```
fit = m.fit(cov_type="HC1")
fit.params
fit.bse
fit.pvalues
fit.conf_int()
fit.params["C(gender) [T.M]"]
fit.summary()
```

robust SE로 추정
계수 $\hat{\beta}$ (Series, index = 항 이름)
표준오차 SE
p-value
95% 신뢰구간 (두 열)
0.088 (\$6.9의 m2)
전체 표

※ `summary()` 표에서 볼 곳: `coef` (계수), `std err`, `P>|z|` (p-value), `[0.025 0.975]` (신뢰구간). 나머지(Omnibus, Durbin-Watson 등)는 이 분석에서는 무시해도 됩니다.

이 장과 본문의 관계

본문의 각 장 끝에 “**pandas 코드**” 소절이 있어서, 그 장의 숫자를 만든 코드를 그대로 보여 줍니다. 모두 이 장의 `df` (600행), `d` (결측 제거 582행)에서 출발합니다.

1 전체 지도: 데이터 테이블을 받으면 무엇을 하는가

통계 분석은 “방법을 고르는 일”이 아니라 질문 → 데이터 분류 → 기술 → 모형 → 추정 → 검증 → 해석의 순서로 진행됩니다. 이 책도 이 순서를 그대로 따라갑니다.

단계	하는 일	핵심 질문	이 책
0	질문 정의	무엇을 주장하고 싶은가?	§1
1	데이터 분류	각 열은 어떤 종류이고 어떤 역할인가?	§2
2	기술통계·EDA	그룹별로 숫자가 어떻게 다른가?	§3
3	확률모형	데이터가 어떤 분포에서 나왔다고 볼까?	§4
4	추정 (MoM, MLE)	모형의 parameter 값은 얼마인가?	§4
5	가설검정·신뢰구간	그 차이가 우연일 수 있는가?	§5
6	회귀 (OLS, Logistic)	다른 변수를 통제해도 차이가 남는가?	§6, §7
7	Bayesian 분석	차이가 있을 확률은 얼마인가?	§8
8	공정성·인과 해석	이걸 “차별”이라고 부를 수 있는가?	§9

데이터에 적용: 이번 datathon의 질문

“채용 과정에 gender bias가 있는가?” 이 질문을 통계적으로 다룰 수 있는 형태로 바꾸면 다음 세 가지가 됩니다.

1. **Raw gap**: 남성과 여성의 합격률이 다른가?
2. **Adjusted gap**: 학위, 시험점수, 경력, 부서를 같게 맞춘 상태에서도 다른가?
3. **Heterogeneity**: 그 차이가 부서마다 다른가?

결론을 미리 보면: (1) 21.8%p 차이, (2) 평균적으로 8.8%p로 줄어듦, (3) Engineering에서는 남성이 약 +22%p, Marketing에서는 오히려 여성이 약 +10%p. 이 책 전체가 이 세 숫자를 정당하게 얻는 과정입니다.

2 데이터 테이블 분류하기

2.1 관측 단위와 변수

정의

- **Observation unit** (관측 단위): 테이블의 한 행이 나타내는 대상. 여기서는 지원자 한 명.
- **Variable** (변수): 한 열. 행마다 값이 달라질 수 있는 특성.
- **Population** (모집단) vs **Sample** (표본): 우리가 알고 싶은 것은 “이 회사의 채용 과정 전체”이고, 가진 것은 그중 600명의 표본.

2.2 변수의 종류 (Type)

변수의 종류가 쓸 수 있는 방법을 결정합니다. 평균을 낼 수 있는지, 순서가 있는지가 핵심입니다.

종류	의미	요약 방법	예
Binary	값이 두 개 (0/1)	비율 (proportion)	hired, gender
Nominal	순서 없는 범주	빈도, 최빈값	department
Ordinal	순서 있는 범주	중앙값, 빈도	degree (Bachelor < Master < PhD)
Discrete	셀 수 있는 수	평균, 분산	years_experience
Continuous	연속적인 수	평균, 분산, 분포	test_score
Identifier	이름표일 뿐	분석에 쓰지 않음	applicant_id

주의 applicant_id는 숫자이지만 평균을 내면 안 됩니다. “숫자로 적혀 있다”와 “수량이다”는 다릅니다. 같은 이유로 범주형 변수는 회귀에 넣을 때 C(degree)처럼 **dummy variable**로 바꿉니다 (§6.4).

2.3 변수의 역할 (Role): 무엇이 중요한 데이터인가

종류보다 더 중요한 것이 역할입니다. bias 분석에서는 열을 다음 네 가지 역할로 나눕니다.

Bias 분석에서 변수의 네 가지 역할

- **Outcome Y** (결과 변수): 설명하고 싶은 것. → hired
- **Protected attribute A** (보호 속성): 결과에 영향을 주면 안 되는 것. → gender
- **Legitimate qualifications X** (정당한 자격): 결과에 영향을 줘도 되는 것. → test_score, years_experience, degree
- **Structural variable** (구조 변수): 그룹을 나누는 맥락. → department

왜 이 분류가 결정적인가

분석의 핵심 질문은 “X를 같게 맞췄을 때 A가 Y에 영향을 주는가?”입니다. 그래서

- Y와 A가 없으면 분석 자체가 불가능합니다.
- X가 없으면 “남성이 원래 더 자격이 좋아서” 같은 대안 설명을 배제할 수 없습니다.
- department는 애매합니다. 부서를 통제하면 “같은 부서 안에서의 차이”를 보는 것이고, 통제하지 않으면 “여성이 합격률 낮은 부서에 몰리는 구조”까지 포함한 차이를 보는 것입니다. 둘 다 보고하는 것이 정답입니다.

2.4 결측치 (Missing data)

`test_score`에만 결측이 18개 있습니다. 결측은 그 원인에 따라 세 종류로 나눕니다.

- **MCAR** (Missing Completely At Random): 결측이 완전히 무작위. 빼도 편향이 생기지 않습니다.
- **MAR** (Missing At Random): 결측 여부가 관측된 다른 변수(성별, 부서 등)로 설명됩니다.
- **MNAR** (Missing Not At Random): 결측 여부가 그 값 자체와 관련됩니다. 예: 점수가 낮은 사람이 점수를 숨김. 가장 위험한 경우입니다.

데이터에 적용: 결측 18행

18행 중 합격자는 4명 (22%)으로 전체 합격률 32%와 크게 다르지 않고, 600행 중 3%에 불과합니다. 그래서 **listwise deletion** (`df.dropna()`, 582행 사용)을 쓰고, 발표에서 “결측 3%를 제외했으며 제외해도 결론이 같다”고 한 줄 언급하면 충분합니다.

3 기술통계와 EDA: 숫자로 먼저 보기

3.1 기본 도구

정의

- **Sample mean** $\bar{x} = \frac{1}{n} \sum x_i$. 0/1 변수의 평균은 곧 **proportion** (1의 비율)입니다.
- **Sample variance** $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$, **standard deviation** $s = \sqrt{s^2}$.
- **Conditional proportion** $\hat{P}(Y = 1 \mid A = a)$: 그룹 a 안에서의 비율. pandas의 `groupby("gender")["hired"].mean()`이 정확히 이것입니다.
- **Contingency table** (교차표): 두 범주형 변수의 빈도표. `pd.crosstab`.
- **Correlation** $r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \in [-1, 1]$: 선형 관계의 강도.

3.2 우리 데이터의 숫자

데이터에 적용: 그룹별 합격률 (selection rate)

그룹	지원자	합격	합격률
Female	313	68	21.7%
Male	287	125	43.6%
Engineering	326	148	45.4%
Marketing	274	45	16.4%
Bachelor / Master / PhD	311 / 231 / 58		27.0 / 36.8 / 41.4%

자격 변수의 성별 평균은 거의 같습니다: `test_score` 여성 64.7, 남성 65.8; `years_experience` 여성 4.27, 남성 4.65. 상관계수는 `hired-test_score` 0.25, `hired-years_experience` 0.20입니다.

3.3 Confounding과 Simpson's paradox

데이터에 적용: 성별 × 부서 교차표

	여성 지원자	여성 합격률	남성 지원자	남성 합격률
Engineering	100	29.0%	226	52.7%
Marketing	213	18.3%	61	9.8%

여성의 68%는 합격률이 낮은 Marketing에, 남성의 79%는 합격률이 높은 Engineering에 지원했습니다.

정의

- **Confounder** (교란 변수): A 와 Y 둘 다와 관련이 있어서, A 와 Y 사이에 가짜 관계를 만들거나 진짜 관계를 가리는 변수. 여기서는 `department`가 `gender`와도, `hired`와도 관련됩니다.

- **Simpson's paradox**: 전체에서 본 관계가 하위 그룹으로 나누면 약해지거나 뒤집히는 현상.

Marketing에서는 여성 합격률(18.3%)이 남성(9.8%)보다 높는데, 전체로 합치면 여성이 크게 낮아 보입니다. 부분적인 Simpson's paradox입니다. 그래서 전체 숫자만 보고 결론을 내리면 안 되고, 반드시 부서별로 나눠 보거나 회귀에서 통제해야 합니다.

pandas 코드: 그룹별 합격률과 교차표

```
df.groupby("gender")["hired"].agg(["count", "sum", "mean"]) # §3.2 첫 표
# F: 313, 68, 0.217   M: 287, 125, 0.436

df.groupby("department")["hired"].mean() # Engineering 0.454, Marketing 0.164
df.groupby("degree")["hired"].mean() # 0.270 / 0.368 / 0.414

df.groupby("gender")[["test_score", "years_experience"]].mean() # 자격 변수의 성별 평균
df[["years_experience", "test_score", "hired"]].corr() # 상관관계수 행렬

# §3.3 성별 × 부서: 두 열로 groupby 후 unstack으로 펼치기
rate = df.groupby(["department", "gender"])["hired"].mean().unstack()
n = pd.crosstab(df["department"], df["gender"])
# rate: Engineering F 0.290 M 0.527 / Marketing F 0.183 M 0.098
# n : Engineering F 100 M 226 / Marketing F 213 M 61
pd.crosstab(df["gender"], df["department"], normalize="index") # 여성의 68%가 Marketing
```

※ unstack(): 두 단계 index (department, gender) 중 안쪽(gender)을 열로 올려서 2차원 표로 만듭니다. 다음과 같은 결과입니다.

```
df.pivot_table(index="department", columns="gender", values="hired", aggfunc="mean")
```

4 확률모형과 추정: MoM과 MLE

4.1 왜 확률모형이 필요한가

표본 비율 21.7%는 “이 600명”의 사실입니다. 우리가 알고 싶은 것은 “이 채용 과정이 여성을 뽑을 확률”입니다. 같은 과정에서 다른 600명이 지원했다면 숫자가 조금 달랐을 것입니다. 이 흔들림을 다루려면 데이터가 어떤 확률분포에서 나왔다고 가정해야 합니다.

정의

- **Parameter θ** : 모집단의 고정된 미지수. 예: 여성의 진짜 합격 확률 p_F .
- **Statistic**: 표본으로 계산한 값. 예: $\hat{p}_F = 68/313$.
- **Estimator $\hat{\theta}$** : parameter를 추측하는 규칙(공식). 표본에 따라 달라지는 확률변수입니다.
- **Bias**: $\mathbb{E}[\hat{\theta}] - \theta$. 0이면 **unbiased**.
- **Standard error (SE)**: $\hat{\theta}$ 의 표준편차. 추정이 얼마나 흔들리는지.
- **Consistency**: $n \rightarrow \infty$ 일 때 $\hat{\theta} \rightarrow \theta$.

4.2 자주 쓰는 분포

분포	쓰는 곳	평균	분산
Bernoulli(p)	한 명의 합격 여부 (0/1)	p	$p(1-p)$
Bin(n, p)	n 명 중 합격자 수	np	$np(1-p)$
$N(\mu, \sigma^2)$	시험점수, 그리고 큰 표본에서의 추정량	μ	σ^2
Beta(a, b)	확률 p 자체에 대한 믿음 (Bayesian, §8)	$\frac{a}{a+b}$	

Central Limit Theorem (CLT): 독립인 표본의 평균은 n 이 크면 원래 분포와 상관없이 근사적으로 정규분포를 따릅니다:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

이 정리 덕분에 0/1 데이터의 비율에도 z -test와 신뢰구간을 쓸 수 있습니다 (§5).

4.3 Method of Moments (MoM)

MoM의 아이디어

모집단의 moment ($\mathbb{E}[X]$, $\mathbb{E}[X^2]$, ...)를 parameter로 표현한 식에서, 모집단 moment를 표본 moment ($\frac{1}{n} \sum x_i$, $\frac{1}{n} \sum x_i^2$, ...)로 바꿔 넣고 parameter에 대해 푼다.

예 1 (Bernoulli). $Y_i \sim \text{Bernoulli}(p)$ 이면 $\mathbb{E}[Y] = p$. 표본 moment로 바꾸면

$$\hat{p}_{\text{MoM}} = \frac{1}{n} \sum Y_i = \bar{Y}.$$

즉 합격률 그 자체입니다. `groupby(...).mean()` 이 MoM 추정입니다.

예 2 (Normal). $X_i \sim N(\mu, \sigma^2)$ 이면 $\mathbb{E}[X] = \mu$, $\mathbb{E}[X^2] = \sigma^2 + \mu^2$. 바꿔 넣으면

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2.$$

4.4 Maximum Likelihood Estimation (MLE)

MLE의 아이디어

Likelihood $L(\theta) = \prod_i f(x_i | \theta)$: parameter가 θ 일 때 지금 관측한 데이터가 나올 확률(밀도). 이것을 가장 크게 만드는 θ 를 고른다. 곱은 미분하기 어려우므로 **log-likelihood** $\ell(\theta) = \log L(\theta) = \sum_i \log f(x_i | \theta)$ 를 최대화한다 (log는 증가함수라 최대점이 같다).

예 1 (Bernoulli). $f(y | p) = p^y(1-p)^{1-y}$ 이므로, $k = \sum y_i$ 라 하면

$$\ell(p) = \sum_i [y_i \log p + (1 - y_i) \log(1 - p)] = k \log p + (n - k) \log(1 - p).$$

미분해서 0으로 놓으면

$$\ell'(p) = \frac{k}{p} - \frac{n-k}{1-p} = 0 \implies k(1-p) = (n-k)p \implies \hat{p}_{\text{MLE}} = \frac{k}{n}.$$

MoM과 같습니다.

예 2 (Normal). $\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2$. 편미분하면

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2.$$

분모가 n 이라 *biased*입니다 ($\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n}\sigma^2$). 그래서 실무에서는 $n-1$ 로 나눈 s^2 를 씁니다.

데이터에 적용: test_score (582명)

$\hat{\mu} = 65.24$, $\hat{\sigma}_{\text{MLE}}^2 = 135.66$, $s^2 = 135.89$. n 이 크면 둘의 차이는 무시할 만합니다. Shapiro-Wilk 정규성 검정 $p = 0.47$ 로, 정규분포 가정에 문제가 없습니다.

4.5 MoM vs MLE

	MoM	MLE
원리	moment를 맞춘다	데이터의 확률을 최대화
계산	보통 쉽다 (방정식 풀기)	미분, 또는 수치 최적화
효율	분산이 더 클 수 있음	큰 표본에서 분산이 가장 작음 (asymptotically efficient)
분포 가정	moment만 필요	분포 전체가 필요
쓰이는 곳	OLS (§6.6), 빠른 초기값	Logistic regression (§7), 대부분의 통계 모형

MLE의 중요한 성질: 큰 표본에서 $\hat{\theta} \approx N(\theta, I(\theta)^{-1})$. 여기서 $I(\theta) = -\mathbb{E}[\ell''(\theta)]$ 는 **Fisher information**이고, log-likelihood가 꼭대기에서 뾰족할수록 정보가 많고 SE가 작습니다. 회귀 출력의 **std err** 열이 이 공식으로 계산됩니다.

5 가설검정과 신뢰구간 (Frequentist)

5.1 가설검정의 논리: 귀류법과 같은 구조

가설검정의 5단계

1. **Null hypothesis** H_0 : “차이 없음”. 예: $p_M = p_F$.
Alternative hypothesis H_1 : 보이고 싶은 것. 예: $p_M \neq p_F$ (**two-sided**).
2. **Significance level** α 를 미리 정한다 (보통 0.05).
3. **Test statistic** T 를 계산한다: 데이터가 H_0 에서 얼마나 벗어났는지를 하나의 숫자로.
4. H_0 가 참일 때 T 가 따르는 분포(**null distribution**)를 구한다.
5. **p-value** = $P(\text{지금만큼 또는 더 극단적인 } T \mid H_0)$. $p < \alpha$ 이면 H_0 를 기각한다.

귀류법과 비교하면: “ H_0 를 가정했더니 거의 일어날 수 없는 데이터가 나왔다 $\Rightarrow H_0$ 를 의심한다.” 다만 수학의 모순과 달리 “확률이 낮다”일 뿐이라 틀릴 수 있습니다.

	H_0 가 실제로 참	H_0 가 실제로 거짓
H_0 기각	Type I error (확률 α)	올바른 판단 (power = $1 - \beta$)
H_0 기각 안 함	올바른 판단	Type II error (확률 β)

p-value에 대한 흔한 오해

- p 는 “ H_0 가 참일 확률”이 아닙니다. H_0 가 참이라고 가정했을 때 이런 데이터가 나올 확률입니다. “가설이 참일 확률”을 원하면 Bayesian이 필요합니다 (§8).
- $p > 0.05$ 는 “차이가 없다”가 아닙니다. “차이가 있다고 말할 증거가 부족하다”입니다. 표본이 작으면 진짜 차이가 있어도 p 가 큼니다.
- p 가 작다고 차이가 큰 것은 아닙니다. 효과 크기 (**effect size**, 예: 21.8%p)를 항상 같이 보고하세요.

5.2 Two-proportion z-test

$H_0 : p_M = p_F$. CLT에 의해 $\hat{p}_M - \hat{p}_F$ 는 근사적으로 정규분포입니다. H_0 에서는 두 그룹의 확률이 같으므로 합친 비율 $\hat{p} = \frac{k_M + k_F}{n_M + n_F}$ 로 분산을 추정합니다:

$$z = \frac{\hat{p}_M - \hat{p}_F}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_M} + \frac{1}{n_F} \right)}} \stackrel{H_0}{\approx} N(0, 1).$$

데이터에 적용: 성별 합격률

$$\hat{p}_M = 125/287 = 0.4355, \hat{p}_F = 68/313 = 0.2173, \hat{p} = 193/600 = 0.3217.$$

$$z = \frac{0.2183}{\sqrt{0.3217 \cdot 0.6783 \cdot (1/287 + 1/313)}} = \frac{0.2183}{0.0382} = 5.72, \quad p = 1.1 \times 10^{-8}.$$

부서별로 하면: Engineering $z = 3.96$, $p = 7.6 \times 10^{-5}$ (유의); Marketing $z = -1.58$, $p = 0.115$ (유의하지 않음, 남성 표본이 61명뿐).

5.3 Chi-square test of independence

교차표에서 H_0 : “두 변수는 독립”. 독립이면 각 칸의 기대빈도는 $E_{ij} = \frac{(\text{행 합})(\text{열 합})}{n}$ 이고,

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \stackrel{H_0}{\approx} \chi_{(r-1)(c-1)}^2.$$

2×2 표에서는 $\chi^2 = z^2$ 입니다. 실제로 $5.718^2 = 32.70$ 이고, `scipy`의 `chi2_contingency`에 `correction=False`를 주면 똑같이 32.70이 나옵니다. 칸의 기대빈도가 5보다 작으면 **Fisher's exact test**를 씁니다.

5.4 t-test: 평균 비교

연속형 변수의 두 그룹 평균 비교. 분산이 다를 수 있으므로 **Welch's t-test**가 기본입니다:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}.$$

데이터에 적용: 자격에 성별 차이가 있는가?

`test_score`: 남성 65.8, 여성 64.7, $t = 1.10$, $p = 0.27$. 시험점수에 유의한 성별 차이가 없습니다. 따라서 “남성이 점수가 높아서 더 많이 합격했다”는 설명은 성립하기 어렵습니다. 이것도 중요한 결과입니다.

5.5 신뢰구간 (Confidence interval)

$$\hat{\theta} \pm z_{\alpha/2} \cdot \text{SE}(\hat{\theta}), \quad z_{0.025} = 1.96.$$

해석이 까다롭습니다. 95% CI는 “ θ 가 이 구간에 있을 확률이 95%”가 아닙니다. θ 는 고정된 값이라 구간 안에 있거나 없거나 둘 중 하나입니다. 정확한 뜻은 “이 방법으로 구간을 100번 만들면 약 95번은 θ 를 포함한다”입니다.

데이터에 적용: 여성 합격률의 95% CI

$$\hat{p}_F = 0.217, \text{SE} = \sqrt{0.217 \cdot 0.783/313} = 0.0233, \text{CI} = [0.172, 0.263].$$

5.6 검정 선택표

비교 대상	검정	Python
두 그룹의 비율	two-proportion z , χ^2 , Fisher	<code>proportions_ztest</code> , <code>chi2_contingency</code>
두 그룹의 평균	Welch t (비모수: Mann-Whitney U)	<code>ttest_ind</code> , <code>equal_var=False</code>
세 그룹 이상의 평균	ANOVA (비모수: Kruskal-Wallis)	<code>f_oneway</code>
여러 변수를 동시에 통제	회귀 계수의 t/z test	<code>smf.ols</code> , <code>smf.logit</code>
분포 가정 없이	permutation test, bootstrap (§10)	직접 구현

주의 **Multiple testing**: 검정을 20번 하면 H_0 가 모두 참이어도 평균 1번은 $p < 0.05$ 가 나옵니다. 여러 부서, 여러 학위로 쪼개 검정했다면 **Bonferroni correction** (α/m 기준 사용)을 언급하세요.

pandas 코드: 검정과 신뢰구간

```

from statsmodels.stats.proportion import proportions_ztest, proportion_confint
import scipy.stats as st

# $5.2 two-proportion z-test: [합격자 수], [지원자 수]
k = df.groupby("gender")["hired"].sum()                                # F 68, M 125
n = df.groupby("gender")["hired"].count()                              # F 313, M 287
z, p = proportions_ztest([k["M"], k["F"]], [n["M"], n["F"]])          # z = 5.72, p = 1.1e-08
# 부서별로 반복: 조건으로 행을 고른 뒤 같은 계산
for dept, sub in df.groupby("department"):
    kk = sub.groupby("gender")["hired"].sum(); nn = sub.groupby("gender")["hired"].count()
    print(dept, proportions_ztest([kk["M"], kk["F"]], [nn["M"], nn["F"]]))
# Engineering z = 3.96, p = 7.6e-05   Marketing z = -1.58, p = 0.115
# $5.3 chi-square: 교차표를 그대로 입력
table = pd.crosstab(df["gender"], df["hired"])
chi2, p, dof, expected = st.chi2_contingency(table, correction=False) # 32.70, 1.1e-08,
1
# $5.4 Welch t-test: 두 그룹의 점수를 따로 꺼내서
male = df.loc[df["gender"] == "M", "test_score"].dropna()
female = df.loc[df["gender"] == "F", "test_score"].dropna()
st.ttest_ind(male, female, equal_var=False)                            # t = 1.10, p = 0.27
# $5.5 신뢰구간
proportion_confint(68, 313, method="normal")                          # (0.172, 0.263)

```

※ `df.loc[행 조건, 열 이름]`: 조건에 맞는 행에서 한 열만 꺼냅니다. `df[조건][“열”]` 보다 안전하고 빠릅니다.

※ `for dept, sub in df.groupby(...)`: `groupby` 결과를 반복하면 (그룹 이름, 그 그룹의 DataFrame) 쌍이 나옵니다. 하위 그룹별로 같은 분석을 반복할 때 씁니다.

6 선형회귀와 OLS

6.1 왜 회귀가 필요한가

z -test는 두 그룹만 비교합니다. “점수, 경력, 학위, 부서를 모두 같게 맞췄을 때”를 표현하려면 여러 변수를 한 번에 다루는 모형이 필요합니다. 그것이 회귀입니다.

6.2 모형

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i | x_i] = 0.$$

행렬로 쓰면 $y = X\beta + \varepsilon$ 입니다. X 는 $n \times (k+1)$ 행렬이고, 첫 열은 모두 1(절편용)입니다.

β_j 의 뜻: 다른 변수를 모두 고정한 채 x_j 만 1 늘렸을 때 $\mathbb{E}[Y]$ 의 변화량. “통제한다”는 말의 수학적 의미가 바로 이것입니다.

6.3 OLS: 최소제곱 추정

Residual $e_i = y_i - x_i^\top \beta$ 를 제곱해서 더한 값을 최소화합니다:

$$S(\beta) = \sum_i (y_i - x_i^\top \beta)^2 = (y - X\beta)^\top (y - X\beta).$$

β 로 미분해서 0으로 놓으면 (**normal equations**):

$$\frac{\partial S}{\partial \beta} = -2X^\top (y - X\beta) = 0 \implies X^\top X \hat{\beta} = X^\top y \implies \hat{\beta} = (X^\top X)^{-1} X^\top y.$$

변수가 하나일 때 풀어 쓰면

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

기하학적 의미 (선형대수와 연결): $X\hat{\beta}$ 는 y 를 X 의 column space 위로 **orthogonal projection**한 것입니다. normal equation $X^\top (y - X\hat{\beta}) = 0$ 은 “residual 벡터가 모든 열과 직교한다”는 뜻입니다.

6.4 Dummy variable: 범주형 변수 넣기

범주가 m 개인 변수는 기준 범주(**reference category**)를 하나 정하고 나머지 $m-1$ 개를 0/1 열로 만듭니다. C(degree)는 Bachelor를 기준으로 Master, PhD 두 열을 만듭니다. 계수는 “Bachelor에 비해 얼마나 다른가”입니다. (m 개를 모두 넣으면 절편 열과 완전히 겹쳐 $X^\top X$ 의 역행렬이 없습니다: **dummy variable trap**.)

중요한 사실: dummy 하나 $D \in \{0, 1\}$ 만 넣은 회귀 $Y = \beta_0 + \beta_1 D$ 에서

$$\hat{\beta}_0 = \bar{y}_{D=0}, \quad \hat{\beta}_1 = \bar{y}_{D=1} - \bar{y}_{D=0}.$$

즉 OLS 계수는 정확히 두 그룹의 평균 차이입니다. 증명은 연습 문제 6.

6.5 Linear Probability Model (LPM)

$Y \in \{0, 1\}$ 이면 $\mathbb{E}[Y | X] = P(Y = 1 | X)$ 이므로, OLS 회귀는 합격 확률을 선형으로 모델링하는 것입니다. 계수 단위가 확률(%p)이라 해석이 가장 쉽습니다. 단점 세 가지:

1. **Heteroskedasticity**: $\text{Var}(Y | X) = p(X)(1 - p(X))$ 가 X 마다 달라서 일반 SE 공식이 틀립니다.
해결: **robust SE** (`cov_type="HC1"`).
 2. 예측값이 $[0, 1]$ 을 벗어날 수 있습니다.
 3. 효과가 확률 수준과 상관없이 일정하다고 가정합니다.
- 2, 3번은 logistic regression이 해결합니다 (§7).

6.6 OLS는 MoM이기도 하다

모형 가정 $\mathbb{E}[\varepsilon | X] = 0$ 에서 $\mathbb{E}[X\varepsilon] = \mathbb{E}[X(Y - X^\top \beta)] = 0$ (population moment condition)이 나온다. 이것의 sample analog

$$\frac{1}{n} \sum_i x_i(y_i - x_i^\top \hat{\beta}) = 0$$

는 정확히 normal equation입니다. 그리고 오차가 정규분포라고 가정하면 OLS는 MLE와도 같습니다. **OLS = MoM = (정규 오차 하의) MLE**, 세 관점이 한 점에서 만납니다.

Gauss–Markov theorem: 오차의 분산이 같고 서로 상관이 없으면, OLS는 선형 unbiased estimator 중 분산이 가장 작습니다 (**BLUE**).

6.7 회귀 계수의 검정

각 계수에 대해 $H_0: \beta_j = 0$ 을 검정합니다. $t = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$ 이고, `summary()` 표의 $P > |z|$ 열이 그 p-value입니다. 95% CI는 $\hat{\beta}_j \pm 1.96 \text{SE}$. R^2 는 Y 의 분산 중 모형이 설명하는 비율입니다 (0/1 결과에서는 원래 낮게 나오니 신경 쓰지 않아도 됩니다).

6.8 Omitted variable bias: 왜 통제가 필요한가

진짜 모형이 $Y = \beta_0 + \beta_1 A + \beta_2 Z + \varepsilon$ 인데 Z (예: 부서)를 빼고 Y 를 A 에만 회귀하면

$$\mathbb{E}[\tilde{\beta}_1] = \beta_1 + \beta_2 \cdot \delta, \quad \delta = \frac{\text{Cov}(A, Z)}{\text{Var}(A)}.$$

Z 가 Y 와 관련 있고 ($\beta_2 \neq 0$) A 와도 관련 있으면 ($\delta \neq 0$) 성별 계수가 편향됩니다. 여기서 Marketing의 계수는 음수 ($\beta_2 < 0$)이고 남성은 Marketing에 덜 지원하므로 ($\delta < 0$), 편향 $\beta_2 \delta > 0$: 부서를 빼면 성별 효과가 과대 추정됩니다. 아래 $m1 \rightarrow m2$ 에서 0.216이 0.088로 줄어드는 것이 바로 이것입니다.

6.9 Interaction

$C(\text{gender}) * C(\text{department})$ 는 $\beta_1 \text{Male} + \beta_2 \text{Mkt} + \beta_3 (\text{Male} \times \text{Mkt})$ 를 넣습니다. 그러면 남성 효과는 Engineering에서 β_1 , Marketing에서 $\beta_1 + \beta_3$ 로 부서마다 달라질 수 있습니다.

데이터에 적용: 세 개의 LPM (582행, robust SE)

모형	수식	남성 효과	95% CI / p
m1	<code>hired ~ C(gender)</code>	+0.216	$p = 1.5 \times 10^{-8}$
m2	+ 부서, 학위, 점수, 경력	+0.088	$[0.012, 0.164], p = 0.023$
m3	+ 성별 × 부서	Eng +0.218 Mkt 0.218 - 0.319 = -0.101	$[0.112, 0.323]$ 상호작용 $[-0.460, -0.178]$

m2의 다른 계수: Marketing -0.221, Master +0.084, PhD +0.120, 점수 1점당 +0.010, 경력 1

년당 +0.034. 부서를 나눠 따로 회귀해도 Engineering +0.210 ($p = 10^{-4}$), Marketing -0.098 ($p = 0.034$)로 같은 결론입니다.

해석. m2의 8.8%p는 정반대인 두 부서 효과의 평균이라 오해를 부릅니다. 핵심 결론은 m3입니다: “Engineering에서는 자격과 학위를 통제해도 남성의 합격 확률이 약 22%p 높다.”

pandas 코드: 세 개의 LPM

```
import statsmodels.formula.api as smf
d = df.dropna() # 582행
m1 = smf.ols("hired ~ C(gender)", data=d).fit(cov_type="HC1")
m2 = smf.ols("hired ~ C(gender) + C(department) + C(degree) + test_score +
years_experience",
data=d).fit(cov_type="HC1")
m3 = smf.ols("hired ~ C(gender)*C(department) + C(degree) + test_score +
years_experience",
data=d).fit(cov_type="HC1")
# 세 모형의 성별 계수를 한 표로
pd.DataFrame({name: [m.params["C(gender)[T.M]"], m.pvalues["C(gender)[T.M]"]
for name, m in [("m1", m1), ("m2", m2), ("m3", m3)]},
index=["coef", "p"])
# m1 0.216 (1.5e-08)    m2 0.088 (0.023)    m3 0.218 (Engineering에서의 효과)
m3.params["C(gender)[T.M]:C(department)[T.Marketing]"] # -0.319 (interaction)
m2.conf_int().loc["C(gender)[T.M]"] # [0.012, 0.164]
# 부서별로 따로 회귀 (interaction의 다른 표현)
for dept, sub in d.groupby("department"):
f = smf.ols("hired ~ C(gender) + C(degree) + test_score + years_experience",
sub).fit(cov_type="HC1")
print(dept, f.params["C(gender)[T.M]"].round(3), f.pvalues["C(gender)[T.M]"].round(3))
# Engineering 0.21 (0.000)    Marketing -0.098 (0.034)
(m3.fittedvalues < 0).sum() # 43: 확률이 음수로 예측된 사람 수 (LPM 단점)
```

※ 수식의 *는 “두 변수 + 둘의 곱”을 모두 넣으라는 뜻이고, :는 곱 항만 넣습니다. $C(gender)*C(department) = C(gender) + C(department) + C(gender):C(department)$.

※ 계수 이름은 m2.params.index로 확인합니다. 범주형은 C(변수)[T.범주] 형식입니다.

7 Logistic regression과 GLM

7.1 아이디어: log-odds를 직선으로

확률 $p \in (0, 1)$ 을 범위 제한이 없는 수로 바꿉니다:

$$p \in (0, 1) \longrightarrow \text{odds} = \frac{p}{1-p} \in (0, \infty) \longrightarrow \text{logit}(p) = \log \frac{p}{1-p} \in (-\infty, \infty).$$

이제 logit을 직선으로 놓습니다:

$$\log \frac{p_i}{1-p_i} = x_i^\top \beta \iff p_i = \sigma(x_i^\top \beta) = \frac{1}{1 + e^{-x_i^\top \beta}}.$$

σ 는 **sigmoid** 함수로, 어떤 실수를 넣어도 $(0, 1)$ 사이 값이 나오는 S자 곡선입니다.

7.2 추정: MLE

각 지원자가 $Y_i \sim \text{Bernoulli}(p_i)$ 이므로 §4.4의 Bernoulli log-likelihood에 $p_i = \sigma(x_i^\top \beta)$ 를 넣습니다:

$$\ell(\beta) = \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

$\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 를 쓰면 (연습 문제 8)

$$\frac{\partial \ell}{\partial \beta} = \sum_i x_i (y_i - p_i) = X^\top (y - p) = 0.$$

OLS의 normal equation $X^\top (y - X\beta) = 0$ 과 같은 모양입니다. 다만 p 가 β 의 비선형 함수라 닫힌 해가 없어서 **Newton's method**로 반복합니다:

$$\beta^{(t+1)} = \beta^{(t)} - H^{-1} \nabla \ell, \quad H = -X^\top W X, \quad W = \text{diag}(p_i(1 - p_i)).$$

ℓ 은 concave라서 최댓값이 하나뿐이고, 보통 5-10번 만에 수렴합니다.

7.3 계수 해석: odds ratio와 한계효과

- β_j : x_j 가 1 늘면 log-odds가 β_j 만큼 증가.
- e^{β_j} : **odds ratio**. odds가 몇 배가 되는가.
- **Average marginal effect (AME)**: 확률 단위의 효과를 사람마다 계산해서 평균한 값. LPM 계수와 직접 비교할 수 있습니다 (`get_margeff()`).

주의 odds ratio 2는 “확률이 2배”가 아닙니다. $p = 0.2$ 이면 $\text{odds} = 0.25$, 2배 하면 0.5, 즉 $p = 0.33$ 입니다.

7.4 모형 비교: Likelihood ratio test, AIC, BIC

모형 B가 모형 A에 변수를 q 개 추가한 것이라면 (**nested models**):

$$\text{LR} = 2(\ell_B - \ell_A) \stackrel{H_0}{\approx} \chi_q^2.$$

AIC = $-2\ell + 2k$, **BIC** = $-2\ell + k \log n$: 작을수록 좋습니다. 변수를 많이 쓰면 벌점을 줍니다.

데이터에 적용: Logistic 결과 vs LPM

모형	logit 계수	odds ratio	AME (확률)	LPM 계수
m1 남성	1.007	2.74	0.209	0.216
m2 남성	0.470	1.60	0.082	0.088
m3 남성 (Eng)	1.064	2.90	부서별 확률 차이: Eng +0.219 / +0.218	
m3 남성×Mkt	-2.046	0.13	Mkt -0.104 / -0.101	

m2 → m3 LR test: LR = 15.2, $p = 9.5 \times 10^{-5}$. AIC 620.7 → 607.4, BIC 651.2 → 642.4로 둘 다 감소. **Interaction**은 통계적으로 필요합니다. 그리고 logistic과 LPM의 결론이 확률 단위로 거의 같습니다.

7.5 GLM: 하나의 틀

LPM과 logistic은 **Generalized Linear Model**의 특수한 경우입니다: $g(\mathbb{E}[Y | X]) = X^\top \beta$.

Y 의 종류	분포	link g	모형
연속형	Normal	identity	선형회귀 (OLS)
0/1	Bernoulli	logit	Logistic regression
0/1	Bernoulli	probit (Φ^{-1})	Probit regression
횟수 (0, 1, 2, ...)	Poisson	log	Poisson regression

pandas 코드: Logistic regression

```

12 = smf.logit("hired ~ C(gender) + C(department) + C(degree) + test_score +
years_experience", d).fit()
13 = smf.logit("hired ~ C(gender)*C(department) + C(degree) + test_score +
years_experience", d).fit()
np.exp(12.params["C(gender)[T.M]"]) # odds ratio 1.60
12.get_margeff().summary_frame() # 평균 한계효과 (확률 단위): 성별 0.082
# 부서별 성별 효과를 확률로: 모든 사람을 남/여로 바꿔 예측한 뒤 평균 비교
for dept in ["Engineering", "Marketing"]:
    sub = d[d["department"] == dept]
    pm = 13.predict(sub.assign(gender="M")).mean()
    pf = 13.predict(sub.assign(gender="F")).mean()
    print(dept, round(pm - pf, 3)) # Engineering +0.219, Marketing -0.104
# §7.4 Likelihood ratio test
LR = 2 * (13.llf - 12.llf) # 15.2
st.chi2.sf(LR, df=1) # p = 9.5e-05
12.aic, 13.aic # 620.7, 607.4

```

※ `sub.assign(gender="M")`: `sub`를 복사하면서 `gender` 열을 전부 "M"으로 바꾼 새 표. 원본은 그대로입니다. "모든 사람이 남성이었다면"의 예측 확률을 구하는 반사실(counterfactual) 계산입니다.

※ `.llf`: log-likelihood $\ell(\hat{\beta})$ 값. `.fit()`이 Newton's method로 최대화한 결과입니다 (§7.2).

8 Bayesian 통계: 왜, 어떻게

8.1 두 관점의 차이

Frequentist vs Bayesian

- **Frequentist**: 확률 = 반복했을 때의 빈도. parameter θ 는 고정된 미지수이고, 확률은 데이터에만 붙습니다. 그래서 “ $p_M > p_F$ 일 확률”이라는 말을 할 수 없습니다.
- **Bayesian**: 확률 = 믿음의 정도. θ 도 불확실하므로 확률분포로 표현합니다. 데이터를 보고 그 분포를 업데이트합니다.

8.2 Bayes' theorem

$$\underbrace{p(\theta | \text{data})}_{\text{posterior}} = \frac{\overbrace{p(\text{data} | \theta)}^{\text{likelihood}} \overbrace{p(\theta)}^{\text{prior}}}{p(\text{data})} \propto \text{likelihood} \times \text{prior}.$$

- **Prior** $p(\theta)$: 데이터를 보기 전의 믿음.
- **Likelihood**: MLE에서 쓴 것과 같은 함수입니다.
- **Posterior**: 데이터를 본 후의 믿음. 모든 결론은 여기서 나옵니다.

8.3 Beta-Binomial: 합격률의 Bayesian 추정

Prior $p \sim \text{Beta}(a, b)$, 즉 $p(p) \propto p^{a-1}(1-p)^{b-1}$. n 명 중 k 명 합격이면 likelihood $\propto p^k(1-p)^{n-k}$. 곱하면

$$p(p | k) \propto p^{k+a-1}(1-p)^{n-k+b-1} \implies p | k \sim \text{Beta}(a+k, b+n-k).$$

posterior가 prior와 같은 분포족으로 나옵니다 (**conjugate prior**). 해석: a, b 는 “미리 본 가상의 합격/불합격 수”입니다. $\text{Beta}(1, 1)$ 은 $[0, 1]$ 위의 uniform, 즉 “아무것도 모른다”는 prior입니다.

Posterior mean = $\frac{a+k}{a+b+n}$ 는 prior mean $\frac{a}{a+b}$ 과 MLE $\frac{k}{n}$ 의 가중평균이고, n 이 클수록 MLE에 가까워집니다. 데이터가 많으면 prior는 거의 상관이 없어집니다.

데이터에 적용: Prior Beta(1, 1)로 계산

그룹	posterior	95% credible interval	비교: frequentist 95% CI
여성 (68/313)	Beta(69, 246)	[0.175, 0.266]	[0.172, 0.263]
남성 (125/287)	Beta(126, 163)	[0.379, 0.493]	[0.378, 0.493]

posterior에서 p_M 과 p_F 를 20만 번씩 뽑아 차이를 계산하면:

	$P(p_M > p_F \text{data})$	$p_M - p_F$ 중앙값	95% credible interval
전체	≈ 1.000	0.217	[0.144, 0.289]
Engineering	0.99997	0.233	[0.121, 0.338]
Marketing	0.065	-0.078	[-0.161, 0.025]

Marketing: frequentist 검정은 “ $p = 0.115$, 유의하지 않음”으로 끝납니다. Bayesian은 “여성의 합격률이 더 높을 확률이 93.5%”라고 말할 수 있습니다. 같은 데이터에서 훨씬 쓸모 있는 문장입니다.

8.4 왜 Bayesian을 많이 쓰는가

Bayesian을 쓰는 다섯 가지 이유

1. 질문에 직접 답한다. 사람들이 실제로 궁금한 것은 “차이가 있을 확률”이지 “차이가 없다고 가정했을 때 이 데이터가 나올 확률”(p-value)이 아닙니다. 의사결정(A/B 테스트, 정책)에서 특히 중요합니다.
2. 작은 그룹에 강하다. Marketing 남성은 61명, 합격 6명입니다. 이렇게 작은 셀은 MLE가 크게 흔들립니다. prior가 극단적인 추정을 적당히 잡아 줍니다 (**shrinkage**). 교차 그룹(예: 성별×부서×학위)으로 쪼갤수록 이 장점이 커집니다.
3. 불확실성이 자연스럽게 전파된다. posterior 샘플로 disparate impact ratio p_F/p_M 같은 복잡한 값도 그냥 계산하면 분포가 나옵니다. 예: Engineering에서 $P(p_F/p_M < 0.8) = 0.991$. frequentist로는 delta method 같은 근사가 필요합니다.
4. 순차적 업데이트. 오늘의 posterior가 내일의 prior가 됩니다. 데이터가 들어올 때마다 갱신하는 시스템(추천, 광고, 임상시험)에 적합합니다.
5. 기존 지식을 넣을 수 있다. “업계 평균 합격률이 30% 근처”라는 정보를 prior로 반영할 수 있습니다. 반대로 이것은 비판의 대상이기도 합니다. 그래서 prior를 바꿔도 결론이 같은지 보여주는 **sensitivity analysis**가 필수입니다.

8.5 Bayesian 가설 비교

- **Posterior probability**: $P(p_M > p_F \mid \text{data})$ 를 직접 보고합니다. 가장 간단하고 실용적입니다.
- **Credible interval**이 0을 포함하는지 봅니다. 해석은 말 그대로 “ θ 가 이 구간에 있을 확률이 95%”입니다 (CI와 다른 점).
- **Bayes factor** $BF_{10} = \frac{p(\text{data} \mid H_1)}{p(\text{data} \mid H_0)}$: 데이터가 H_1 을 H_0 보다 몇 배 지지하는가. 3 이상이면 “지지”, 10 이상이면 “강한 지지”로 읽는 관행이 있습니다.

8.6 Bayesian 회귀와 MAP

회귀 계수에도 prior를 줄 수 있습니다: $\beta_j \sim N(0, \tau^2)$. posterior를 최대화하는 점 (**MAP**, maximum a posteriori)을 구하면

$$\hat{\beta}_{\text{MAP}} = \arg \max_{\beta} \left[\ell(\beta) - \frac{1}{2\tau^2} \sum_j \beta_j^2 \right].$$

이것은 정확히 **Ridge regression** (L_2 정규화)입니다. Laplace prior를 쓰면 **Lasso** (L_1)가 됩니다. 머신러닝의 정규화는 Bayesian prior를 다르게 본 것입니다. 전체 posterior를 구하려면 **MCMC**를 씁니다 (Python: PyMC, bambi).

8.7 요약표

	Frequentist	Bayesian
parameter	고정된 미지수	확률분포
추정	MLE, MoM (점 하나)	posterior 분포 전체
구간	Confidence interval	Credible interval
가설	p-value, 기각/채택	$P(H \text{data})$, Bayes factor
사전 지식	쓰지 않음	prior로 반영
작은 표본	불안정	shrinkage로 안정
비판	p-value 오해가 쉬움	prior가 주관적

데이터가 충분하면 두 방법의 숫자는 거의 같습니다 (위 표에서 CI와 credible interval이 거의 일치). 차이는 해석과 작은 표본에서 나타납니다.

pandas 코드: Beta-Binomial 시뮬레이션

```

rng = np.random.default_rng(1)
def prob_male_higher(sub, draws=200_000):
    k = sub.groupby("gender")["hired"].sum()
    n = sub.groupby("gender")["hired"].count()
    pm = rng.beta(1 + k["M"], 1 + n["M"] - k["M"], draws)
    pf = rng.beta(1 + k["F"], 1 + n["F"] - k["F"], draws)
    diff = pm - pf
    return (diff > 0).mean(), np.percentile(diff, [2.5, 50, 97.5])
prob_male_higher(df)
for dept, sub in df.groupby("department"):
    print(dept, prob_male_higher(sub))
# Engineering (0.99997, [0.121, 0.233, 0.338])
# Marketing (0.065, [-0.161, -0.078, 0.025]) → P(여성이 높음) = 0.935
st.beta(69, 246).ppf([0.025, 0.975]) # 여성 credible interval [0.175, 0.266]

```

※ 사후분포에서 숫자를 많이 뽑아 (rng.beta) 원하는 양(차이, 비율)을 직접 계산하는 방식입니다. 공식이 없어도 (diff > 0).mean() 한 줄로 “남성이 높을 확률”이 나옵니다.

9 공정성 지표와 인과의 한계

9.1 Fairness metrics

정의 ($\hat{Y}$ = 채용 결정, A = 성별, Y^* = 실제 적합성)

- **Demographic parity:** $P(\hat{Y} = 1 | A = F) = P(\hat{Y} = 1 | A = M)$. 합격률 자체가 같아야 한다.
- **Disparate impact ratio:** $\frac{P(\hat{Y} = 1 | A = F)}{P(\hat{Y} = 1 | A = M)}$. 0.8 미만이면 미국 EEOC의 **four-fifths rule**상 adverse impact로 봅니다.
- **Equalized odds:** 실제 자격 Y^* 가 같은 사람끼리는 합격률이 같아야 한다: $P(\hat{Y} = 1 | Y^* = y, A = F) = P(\hat{Y} = 1 | Y^* = y, A = M)$.
- **Conditional parity:** 정당한 자격 X 가 같으면 합격률이 같아야 한다. 회귀의 통제가 바로 이것을 검사합니다.

데이터에 적용: Disparate impact

전체 $0.217/0.436 = 0.50$, Engineering $0.290/0.527 = 0.55$: 둘 다 0.8에 크게 못 미칩니다. Marketing에서는 반대로 남성/여성 = $0.098/0.183 = 0.54$ 로 남성이 불리합니다.

Impossibility theorem (Kleinberg et al. 2016; Chouldechova 2017): 그룹 간 base rate가 다른 calibration과 equalized odds 같은 여러 공정성 기준을 동시에 만족할 수 없습니다. 그래서 “어떤 공정성 기준을 썼는가”를 명시해야 합니다.

9.2 상관은 인과가 아니다

회귀의 남성 계수가 유의하다는 것은 “관측된 자격 변수로 설명되지 않는 격차가 있다”까지입니다. “차별 때문”이라고 말하려면 다음 대안을 배제해야 합니다.

- 관측되지 않은 변수: 면접 성적, 추천서, 직무 세부 분야 등. 성별과 관련이 있다면 omitted variable bias가 생깁니다 (§6.8).
- 선택 편향: 지원자 풀 자체가 다르게 구성됐을 수 있습니다.
- **Bad control:** 차별의 결과일 수 있는 변수(예: 차별 때문에 Marketing으로 유도된 경우의 부서)를 통제하면 오히려 차별을 가립니다.

인과를 주장하려면 **randomized experiment** (예: 같은 이력서에 이름만 바꿔 보내는 audit study)나 **causal inference** 방법(matching, instrumental variables, difference-in-differences)이 필요합니다.

발표에서 쓸 정직한 결론 문장

“Engineering에서는 시험점수, 경력, 학위를 통제한 후에도 남성의 합격 확률이 약 22%p 높았다 (95% CI 11–32%p). Logistic regression과 Bayesian 분석에서도 같은 결론이 나왔다. 관측 데이터므로 인과를 단정할 수는 없지만, 데이터에 있는 자격 변수로는 이 격차가 설명되지 않는다. Marketing에서는 반대로 여성이 약 10%p 높았으며, 남성 지원자가 61명뿐이라 불확실성이 크다.”

pandas 코드: 공정성 지표

```
rate = df.groupby("gender")["hired"].mean()
rate["F"] / rate["M"]                                # disparate impact 0.50 (< 0.8)
by_dept = df.groupby(["department", "gender"])["hired"].mean().unstack()
by_dept["F"] / by_dept["M"]                          # Engineering 0.55, Marketing 1.86
by_dept.stack().idxmin()                             # 가장 낮은 셀: (Marketing, M)
```

10 그 밖의 도구들

도구	한 줄 설명	언제 쓰나
Bootstrap	표본에서 복원추출을 반복해 추정량의 분포를 만든다	공식이 없는 통계량의 SE/CI (예: DI ratio)
Permutation test	성별 라벨을 무작위로 섞어 null distribution을 직접 만든다	분포 가정 없이 검정
Mann–Whitney U	순위 기반 두 그룹 비교	정규성이 의심될 때
ANOVA	세 그룹 이상 평균 비교 (F -test)	학위 3종의 점수 비교
Bonferroni / FDR	다중검정 보정	하위 그룹을 많이 쪼갬을 때
Ridge / Lasso	계수에 벌점 (= Bayesian prior)	변수가 많을 때, 예측
Cross-validation	데이터를 나눠 예측 성능을 정직하게 평가	예측 모형 비교
Decision tree, Random forest, XGBoost	비선형·상호작용을 자동으로 잡는 예측 모형	예측이 목적일 때 (해석은 SHAP)
Matching / Propensity score	자격이 비슷한 남녀를 짝지어 비교	회귀의 선형 가정이 의심될 때
Oaxaca–Blinder decomposition	격차를 “자격 차이로 설명되는 부분”과 “설명되지 않는 부분”으로 분해	노동경제학의 임금·채용 격차 분석

설명(inference) vs 예측(prediction). 이번 datathon은 “bias가 있는가”를 묻는 설명 문제이므로 해석 가능한 LPM/logistic이 주인공입니다. XGBoost 같은 모형은 정확도는 높지만 “성별 효과가 몇 %p인가”에 바로 답하지 못합니다.

11 Datathon 체크리스트

1. `df.info()`, `df.isna().sum()`, `df.describe()`로 구조 파악 (10분)
2. 각 열을 $Y / A / X$ / 구조 변수로 분류 (§2)
3. 그룹별 합격률 표, 성별 $\times$ 부서 교차표 (§3) $\rightarrow$ Simpson 확인
4. 자격 변수의 성별 차이 t -test (§5.4): “자격 차이 때문은 아니다”의 근거
5. Raw gap 검정: z -test 또는 χ^2 (§5)
6. LPM $m1 \rightarrow m2 \rightarrow m3$, robust SE (§6)
7. Logistic으로 같은 결론인지 확인, LR test (§7)
8. Bayesian으로 $P(\text{격차} > 0)$, 작은 셀 보완 (§8)
9. Disparate impact, 한계 명시 (§9)
10. 그래프 2-3개: 부서별 성별 합격률 막대그래프, 계수 forest plot, posterior 분포

12 연습 문제

연습 문제

A. 데이터 분류와 기술통계

1. `hiring_practice.csv`의 7개 열 각각에 대해 (a) 변수 종류 (b) bias 분석에서의 역할을 쓰시오.
2. `degree`를 Bachelor=1, Master=2, PhD=3인 하나의 숫자 열로 회귀에 넣는 것과 `C(degree)`로 넣는 것은 무엇이 다른가?
3. 성별×부서 표 (§3.3)에서, 각 부서 안의 합격률이 그대로이고 여성의 부서 지원 비율만 남성과 같다면 (Engineering 79%, Marketing 21%) 여성 전체 합격률은 얼마가 되겠는가?

B. 추정

4. $X_1, \dots, X_n \sim \text{Poisson}(\lambda)$, $P(X = x) = e^{-\lambda} \lambda^x / x!$. λ 의 MoM 추정량과 MLE를 각각 구하시오.
5. $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 에 대해 $\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2$ 임을 보이시오. (힌트: $\sum (X_i - \bar{X})^2 = \sum (X_i - \mu)^2 - n(\bar{X} - \mu)^2$)

C. 회귀

6. $x_i \in \{0, 1\}$ 일 때 $\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \bar{y}_1 - \bar{y}_0$ 임을 보이시오. ($n_1 = x_i = 1$ 인 개수, $\bar{y}_1 =$ 그 그룹의 평균)
7. m3에서 Marketing의 남성 효과는 $\beta_1 + \beta_3$ 이다. 이것의 SE를 구하려면 $\text{SE}(\hat{\beta}_1)$, $\text{SE}(\hat{\beta}_3)$ 외에 무엇이 더 필요한가? 공식을 쓰시오.
8. $\sigma(z) = 1/(1+e^{-z})$ 에 대해 $\sigma'(z) = \sigma(z)(1-\sigma(z))$ 를 보이고, 이를 이용해 $\partial \ell / \partial \beta = \sum x_i (y_i - p_i)$ 를 유도하시오.
9. m2 logistic의 `test_score` 계수는 0.058이다. 점수가 10점 오르면 odds는 몇 배가 되는가? 합격 확률이 0.20인 사람의 확률은 대략 얼마가 되는가?

D. 검정과 Bayesian

10. Marketing의 성별 z-test는 $p = 0.115$ 인데, 부서별 회귀에서 남성 계수는 $p = 0.034$ 이다. 두 결과가 다른 이유를 설명하고, 발표에서 어떻게 말해야 하는지 쓰시오.
11. 친구가 “ $p = 0.115$ 이니까 Marketing에는 성별 차이가 없다”고 말한다. 무엇이 틀렸는가?
12. Prior Beta(2, 8) (“합격률은 대략 20% 정도”라는 믿음)를 쓰고, Marketing 남성 61명 중 6명이 합격했다. posterior 분포와 posterior mean을 구하고, MLE와 비교하시오.
13. 95% confidence interval과 95% credible interval의 해석 차이를 한 문장씩 쓰시오.
14. 부서를 통제하는 것이 오히려 bias를 숨길 수 있는 상황을 하나 들어 설명하시오.

13 풀이

Problem 1.

Answer.

열	종류	역할
applicant_id	identifier	분석에 쓰지 않음
gender	binary (nominal)	protected attribute A
department	nominal	구조 변수 (confounder 후보)
years_experience	discrete	qualification X
degree	ordinal	qualification X
test_score	continuous	qualification X
hired	binary	outcome Y

Problem 2.

Answer. 숫자 하나로 넣으면 Bachelor→Master와 Master→PhD의 효과가 같다고 가정합니다 (계수 하나). $C(\text{degree})$ 는 Master, PhD 각각에 별도 계수를 주어 그런 가정을 하지 않습니다.

Justification. 실제 m2에서 Master +0.084, PhD +0.120으로 간격이 일정하지 않습니다. 범주가 적고 표본이 충분하면 dummy가 안전합니다.

Problem 3.

Answer. $0.79 \times 0.290 + 0.21 \times 0.183 = 0.229 + 0.038 = 0.268$, 약 26.8%.

Justification. 원래 21.7%에서 26.8%로 오르지만, 남성 43.6%에는 여전히 크게 못 미칩니다. 격차의 일부는 부서 구성(confounding) 때문이고, 나머지는 Engineering 안의 격차(29.0% vs 52.7%) 때문입니다. 이것이 m1→m2에서 계수가 줄지만 0이 되지 않는 이유와 같습니다.

Problem 4.

Answer. $\hat{\lambda}_{\text{MoM}} = \hat{\lambda}_{\text{MLE}} = \bar{X}$.

Justification. MoM: $\mathbb{E}[X] = \lambda$ 이므로 $\lambda = \bar{X}$. MLE: $\ell(\lambda) = \sum(-\lambda + x_i \log \lambda - \log x_i!) = -n\lambda + (\sum x_i) \log \lambda + C$. $\ell'(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0 \Rightarrow \hat{\lambda} = \bar{x}$. $\ell'' = -\sum x_i / \lambda^2 < 0$ 이므로 최댓값입니다.

Problem 5.

Justification. 힌트의 항등식은 $X_i - \mu = (X_i - \bar{X}) + (\bar{X} - \mu)$ 를 제곱해서 더하고 $\sum(X_i - \bar{X}) = 0$ 을 쓰면 나옵니다. 기댓값을 취하면

$$\mathbb{E}\left[\sum(X_i - \bar{X})^2\right] = \sum \mathbb{E}[(X_i - \mu)^2] - n\mathbb{E}[(\bar{X} - \mu)^2] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2.$$

n 으로 나누면 $\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n}\sigma^2$. 그래서 unbiased하게 만들려면 $n-1$ 로 나눕니다.

Problem 6.

Justification. $p = n_1/n$ 이라 하면 $\bar{x} = p$. 분모: $x_i^2 = x_i$ 이므로 $\sum(x_i - \bar{x})^2 = \sum x_i - n\bar{x}^2 = n_1 - np^2 = np(1-p)$.

분자: $\sum(x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y} = n_1\bar{y}_1 - np\bar{y}$. 여기서 $\bar{y} = p\bar{y}_1 + (1-p)\bar{y}_0$ 이므로

$$n_1\bar{y}_1 - np(p\bar{y}_1 + (1-p)\bar{y}_0) = np\bar{y}_1(1-p) - np(1-p)\bar{y}_0 = np(1-p)(\bar{y}_1 - \bar{y}_0).$$

나누면 $\hat{\beta}_1 = \bar{y}_1 - \bar{y}_0$. 그리고 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 p = \bar{y}_0$.

Problem 7.

Answer. 두 추정량의 공분산 $\text{Cov}(\hat{\beta}_1, \hat{\beta}_3)$ 가 필요합니다.

$$\text{SE}(\hat{\beta}_1 + \hat{\beta}_3) = \sqrt{\text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_3) + 2\text{Cov}(\hat{\beta}_1, \hat{\beta}_3)}.$$

Justification. 분산의 성질 $\text{Var}(U + V) = \text{Var}U + \text{Var}V + 2\text{Cov}(U, V)$. statsmodels에서는 `m3.cov_params()`에 있고, 간단히 다음처럼 계산할 수 있습니다.

```
m3.t_test("C(gender)[T.M] + C(gender)[T.M]:C(department)[T.Marketing] = 0")
```

또는 부서별로 따로 회귀하면 바로 나옵니다 (Marketing -0.098, SE 0.046).

Problem 8.

Justification. $\sigma(z) = (1 + e^{-z})^{-1}$ 이므로

$$\sigma'(z) = \frac{e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}} = \sigma(z)(1 - \sigma(z)).$$

$p_i = \sigma(z_i)$, $z_i = x_i^\top \beta$ 라 하면 $\partial p_i / \partial \beta = p_i(1 - p_i)x_i$. 따라서

$$\frac{\partial \ell}{\partial \beta} = \sum_i \left[\frac{y_i}{p_i} - \frac{1 - y_i}{1 - p_i} \right] p_i(1 - p_i)x_i = \sum_i [y_i(1 - p_i) - (1 - y_i)p_i]x_i = \sum_i (y_i - p_i)x_i.$$

Problem 9.

Answer. $\text{odds} \times e^{0.58} \approx 1.79$. 확률 $0.20 \rightarrow$ 약 0.31 .

Justification. $p = 0.2$ 이면 $\text{odds} = 0.25$. $0.25 \times 1.79 = 0.447$, $p = 0.447 / 1.447 \approx 0.31$. 같은 10 점이라도 $p = 0.5$ 인 사람은 $\text{odds } 1 \rightarrow 1.79$, $p \approx 0.64$ 로 +14%p 변하고, $p = 0.2$ 인 사람은 +11%p 변합니다. 효과가 확률 수준에 따라 다릅니다 (LPM 단점 3을 logistic이 해결하는 방식).

Problem 10.

Answer. z -test는 raw 비교이고, 회귀는 점수, 경력, 학위를 통제합니다. 통제 변수가 결과를 잘 설명하면 잔차 분산이 줄어 SE가 작아지고, 같은 크기의 효과라도 더 정밀하게 추정됩니다.

Justification. 발표에서는 “Marketing에서 여성이 높은 경향이 있으나, 남성 표본이 61명으로 작아 증거는 중간 정도다 (raw $p = 0.12$, 통제 후 $p = 0.03$, Bayesian $P(p_F > p_M) = 0.94$)”처럼 모두 보고합니다. 원하는 결과가 나올 때까지 모형을 바꾸는 것(p-hacking)으로 보이지 않으려면, 분석 계획을 먼저 정하고 결과를 투명하게 보여 주는 것이 중요합니다.

Problem 11.

Answer. $p > 0.05$ 는 “차이가 없다”는 증거가 아니라 “차이가 있다고 말할 만큼 증거가 충분하지 않다”는 뜻입니다.

Justification. 점추정치는 -8.5%p로 작지 않고, 95% CI도 대부분 음수 쪽입니다. 남성 표본이 61명이라 검정력(power)이 낮습니다. *absence of evidence is not evidence of absence*.

Problem 12.

Answer. posterior $\text{Beta}(2 + 6, 8 + 55) = \text{Beta}(8, 63)$, posterior mean $8/71 \approx 0.113$. MLE = $6/61 \approx 0.098$.

Justification. posterior mean은 prior mean $2/10 = 0.2$ 와 MLE 0.098의 가중평균입니다. 가중치는 prior의 가상 표본 10, 데이터 61입니다: $\frac{10}{71}(0.2) + \frac{61}{71}(0.098) \approx 0.113$. 작은 표본의 극단적인 추정을 prior 쪽으로 조금 당깁니다 (shrinkage).

Problem 13.

Answer.

- **Confidence interval:** 같은 방법으로 반복해서 구간을 만들면 그중 95%가 진짜 θ 를 포함한다. (확률은 구간을 만드는 방법에 붙음)
- **Credible interval:** 데이터와 prior가 주어졌을 때 θ 가 이 구간에 있을 확률이 95%이다. (확률은 θ 에 붙음)

Problem 14.

Answer. 예: 회사가 여성 지원자를 Engineering 대신 Marketing 직무로 유도하거나, Engineering 공고를 여성이 덜 보는 채널에만 냈다면, 부서 배정 자체가 차별의 통로입니다.

Justification. 이 경우 부서는 confounder가 아니라 **mediator** ($\text{gender} \rightarrow \text{department} \rightarrow \text{hired}$)입니다. mediator를 통제하면 그 경로로 흐르는 차별이 계수에서 사라집니다 (**bad control**). 그래서 부서를 통제한 결과(m2)와 통제하지 않은 결과(m1)를 둘 다 보고하고, 각각이 무엇을 측정하는지 설명해야 합니다.

부록: 전체 데이터 (600행)

hiring_practice.csv 전체. 약어: g = gender, dept = department (Eng = Engineering, Mkt = Marketing), exp = years_experience, deg = degree (B = Bachelor, M = Master, P = PhD), score = test_score (- = 결측), h = hired (1 = 합격).

id	g	dept	exp	deg	score	h
1	M	Eng	5	B	69	1
2	F	Mkt	5	M	76	0
3	F	Mkt	4	B	73	0
4	M	Eng	6	M	73	1
5	F	Mkt	5	B	49	1
6	F	Mkt	4	P	62	0
7	F	Mkt	6	P	42	0
8	F	Mkt	3	B	73	0
9	M	Eng	2	B	65	0
10	F	Mkt	3	M	69	0
11	M	Mkt	3	M	64	0
12	M	Eng	5	P	69	1
13	M	Eng	4	M	41	0
14	M	Eng	4	M	69	1
15	M	Eng	4	B	86	1
16	F	Mkt	2	B	70	1
17	M	Eng	5	B	60	1
18	M	Eng	6	M	81	1
19	F	Mkt	6	B	69	0
20	F	Mkt	5	M	70	1
21	F	Eng	4	B	89	0
22	M	Eng	6	M	71	0
23	M	Eng	2	B	57	0
24	M	Eng	6	B	55	0
25	F	Mkt	1	B	79	0
26	M	Eng	7	B	46	1
27	M	Eng	3	M	59	1
28	M	Eng	5	B	57	1
29	F	Eng	5	M	77	1
30	M	Eng	8	M	63	1
31	M	Eng	5	B	67	1
32	M	Eng	6	B	43	0
33	M	Eng	7	M	59	0
34	F	Mkt	3	B	65	0
35	F	Eng	3	B	64	0
36	F	Mkt	4	M	65	0
37	F	Eng	2	M	72	0
38	F	Mkt	3	M	-	0
39	F	Eng	3	M	81	1
40	F	Eng	4	B	59	0
41	M	Eng	6	M	64	1
42	M	Eng	4	P	60	1
43	F	Mkt	3	B	84	0
44	F	Mkt	5	M	80	1
45	F	Eng	7	B	49	1
46	M	Eng	5	M	50	0
47	M	Eng	3	M	76	0
48	F	Mkt	2	M	77	0
49	F	Mkt	8	P	71	0
50	F	Eng	5	P	47	0

id	g	dept	exp	deg	score	h
51	M	Mkt	6	B	58	0
52	F	Eng	8	B	57	1
53	F	Mkt	2	M	62	1
54	F	Mkt	3	B	63	0
55	F	Mkt	0	M	45	0
56	M	Eng	5	P	57	0
57	F	Mkt	6	B	58	1
58	F	Mkt	3	B	40	0
59	M	Mkt	4	P	85	0
60	F	Mkt	5	B	85	0
61	M	Eng	4	B	55	1
62	F	Mkt	3	B	59	0
63	M	Eng	3	P	59	0
64	M	Eng	5	B	56	1
65	M	Eng	7	M	72	1
66	M	Eng	2	B	52	0
67	M	Eng	4	B	76	0
68	M	Mkt	6	M	73	0
69	F	Eng	3	M	65	0
70	F	Mkt	5	B	89	1
71	F	Mkt	5	B	75	0
72	M	Mkt	6	B	61	0
73	M	Eng	6	B	63	0
74	M	Eng	8	M	79	0
75	M	Eng	3	M	56	0
76	F	Mkt	5	B	52	0
77	F	Eng	5	M	75	1
78	M	Eng	2	B	74	1
79	F	Mkt	8	B	56	1
80	F	Mkt	3	B	88	0
81	F	Mkt	4	B	60	0
82	M	Eng	11	B	78	1
83	F	Mkt	8	B	71	0
84	F	Mkt	8	B	56	0
85	F	Mkt	5	P	64	0
86	F	Mkt	6	P	36	0
87	F	Mkt	2	M	77	0
88	M	Eng	6	B	66	1
89	F	Mkt	2	B	77	0
90	F	Mkt	3	M	55	0
91	M	Eng	8	B	63	1
92	F	Mkt	4	B	49	0
93	F	Mkt	6	B	56	0
94	M	Eng	5	B	-	1
95	M	Eng	7	B	72	1
96	F	Mkt	5	M	81	1
97	F	Mkt	5	B	78	0
98	M	Eng	6	M	67	0
99	M	Eng	2	M	35	0
100	M	Eng	4	M	83	1

id	g	dept	exp	deg	score	h
101	F	Mkt	3	B	68	0
102	M	Mkt	4	B	100	0
103	F	Mkt	3	M	88	1
104	F	Mkt	6	B	73	0
105	F	Mkt	3	B	68	0
106	F	Mkt	2	M	62	1
107	M	Eng	3	P	52	1
108	F	Eng	2	M	58	0
109	M	Mkt	9	B	65	0
110	F	Eng	2	M	53	0
111	F	Mkt	4	M	62	0
112	M	Eng	4	B	-	1
113	M	Eng	3	B	53	0
114	M	Eng	5	B	63	0
115	M	Eng	4	M	62	0
116	F	Mkt	5	B	67	0
117	M	Eng	5	B	54	0
118	F	Mkt	7	M	60	0
119	F	Mkt	1	M	38	0
120	M	Eng	5	P	63	1
121	M	Mkt	4	B	73	0
122	M	Eng	3	M	73	0
123	M	Eng	5	M	79	1
124	F	Eng	4	B	53	0
125	M	Mkt	1	M	69	0
126	F	Mkt	4	M	67	0
127	F	Mkt	7	P	62	0
128	F	Mkt	3	B	69	0
129	F	Eng	2	B	66	0
130	M	Eng	5	B	54	0
131	F	Mkt	4	B	85	0
132	M	Mkt	4	M	85	0
133	F	Mkt	1	B	51	0
134	F	Eng	4	B	72	0
135	F	Mkt	3	M	58	0
136	F	Mkt	2	B	-	0
137	M	Eng	2	M	56	0
138	M	Eng	6	B	51	0
139	M	Eng	2	B	71	0
140	F	Mkt	7	B	59	0
141	F	Eng	6	M	68	0
142	M	Eng	6	B	60	0
143	M	Eng	4	B	52	1
144	F	Mkt	4	B	35	0
145	F	Mkt	5	B	77	0
146	M	Mkt	9	B	69	0
147	M	Eng	5	M	-	0
148	M	Mkt	5	B	52	0
149	M	Eng	5	M	62	1
150	M	Eng	5	B	81	0

id	g	dept	exp	deg	score	h
151	M	Eng	2	M	74	0
152	M	Mkt	4	B	75	0
153	F	Mkt	5	B	70	0
154	F	Mkt	6	M	-	0
155	F	Mkt	4	B	67	1
156	M	Mkt	1	P	70	0
157	F	Eng	6	B	58	1
158	F	Eng	5	M	40	0
159	F	Mkt	6	P	70	0
160	F	Mkt	3	B	63	0
161	M	Eng	6	M	47	0
162	F	Mkt	4	M	62	0
163	F	Eng	7	B	79	1
164	M	Eng	4	M	54	0
165	F	Mkt	4	M	61	0
166	F	Mkt	4	M	59	0
167	F	Mkt	2	M	55	0
168	F	Mkt	3	B	57	0
169	F	Mkt	4	B	62	0
170	F	Mkt	4	B	76	0
171	M	Eng	6	M	66	1
172	M	Eng	3	B	75	1
173	M	Mkt	7	M	63	0
174	F	Eng	5	B	66	0
175	M	Eng	3	M	46	1
176	M	Eng	1	M	70	0
177	F	Eng	4	M	76	1
178	M	Eng	3	P	66	1
179	M	Mkt	4	B	77	0
180	M	Eng	4	M	79	1
181	F	Mkt	0	P	67	0
182	M	Eng	6	B	71	0
183	F	Mkt	7	B	88	0
184	F	Mkt	6	B	56	0
185	F	Mkt	3	B	-	0
186	M	Eng	9	M	87	1
187	F	Mkt	4	B	58	0
188	M	Eng	2	B	88	1
189	M	Eng	4	B	67	0
190	M	Mkt	4	B	58	0
191	F	Mkt	5	M	73	0
192	M	Eng	3	B	75	0
193	F	Eng	4	B	60	0
194	M	Eng	6	B	68	0
195	M	Eng	4	B	61	0
196	M	Eng	4	M	59	1
197	M	Eng	6	B	70	1
198	F	Mkt	5	B	77	0
199	M	Mkt	1	B	56	0
200	M	Mkt	5	M	64	0

id	g	dept	exp	deg	score	h
201	M	Eng	4	P	90	1
202	M	Mkt	2	B	73	0
203	F	Eng	6	M	48	1
204	F	Mkt	8	B	75	0
205	M	Mkt	5	B	52	0
206	M	Mkt	1	B	48	0
207	F	Mkt	5	M	65	0
208	F	Mkt	4	M	82	1
209	F	Mkt	4	B	-	0
210	M	Eng	3	B	83	1
211	F	Mkt	4	B	76	0
212	F	Mkt	5	B	62	0
213	F	Eng	5	M	72	0
214	M	Mkt	3	M	87	1
215	M	Eng	6	M	90	1
216	M	Eng	6	M	47	0
217	F	Mkt	2	M	70	1
218	M	Eng	3	M	58	0
219	M	Eng	6	P	77	1
220	F	Mkt	7	M	74	1
221	F	Eng	6	M	66	1
222	M	Eng	3	M	57	1
223	M	Eng	6	B	71	1
224	F	Mkt	8	P	65	1
225	M	Eng	6	B	68	1
226	M	Eng	4	M	64	1
227	M	Eng	7	P	70	0
228	F	Eng	2	B	66	0
229	F	Mkt	3	B	76	0
230	F	Eng	6	B	33	0
231	F	Eng	6	P	63	0
232	F	Eng	2	B	60	0
233	F	Mkt	6	B	70	0
234	F	Eng	5	B	76	0
235	M	Eng	2	P	68	0
236	M	Mkt	7	M	67	0
237	F	Mkt	4	M	60	0
238	F	Mkt	0	M	75	0
239	M	Eng	2	M	88	1
240	M	Eng	7	M	71	0
241	M	Eng	3	B	69	0
242	M	Eng	5	P	71	1
243	M	Eng	6	B	59	1
244	M	Mkt	4	B	56	0
245	M	Eng	3	M	56	1
246	F	Mkt	7	B	68	0
247	M	Mkt	4	B	-	0
248	F	Mkt	1	B	69	0
249	M	Eng	7	M	62	1
250	F	Eng	2	M	73	0

id	g	dept	exp	deg	score	h
251	F	Eng	3	M	62	0
252	F	Mkt	7	M	-	1
253	F	Mkt	3	M	59	0
254	M	Eng	8	B	70	1
255	F	Mkt	2	M	54	0
256	M	Eng	3	M	47	0
257	F	Mkt	7	M	72	0
258	F	Mkt	3	M	82	1
259	F	Mkt	2	B	60	0
260	M	Eng	5	M	35	0
261	F	Eng	6	M	79	0
262	M	Eng	3	B	67	0
263	M	Mkt	9	B	93	0
264	M	Eng	3	B	83	0
265	M	Eng	3	M	59	1
266	M	Eng	3	B	65	0
267	F	Eng	6	B	72	1
268	M	Eng	4	M	58	0
269	F	Mkt	1	M	84	0
270	F	Eng	5	B	73	0
271	F	Eng	4	B	56	0
272	M	Eng	6	M	82	1
273	M	Eng	4	B	50	0
274	M	Eng	2	P	73	1
275	M	Mkt	1	B	51	0
276	M	Mkt	9	B	78	1
277	M	Eng	6	B	56	1
278	F	Mkt	3	B	59	0
279	M	Mkt	1	M	69	0
280	M	Eng	4	M	70	0
281	M	Eng	8	B	70	1
282	M	Mkt	6	B	67	0
283	M	Mkt	1	M	54	0
284	F	Mkt	8	P	63	1
285	F	Mkt	3	B	65	0
286	F	Mkt	4	M	69	0
287	F	Mkt	5	B	58	1
288	F	Eng	4	B	74	0
289	F	Mkt	8	B	60	0
290	M	Eng	4	M	58	1
291	F	Mkt	2	M	54	0
292	F	Mkt	2	B	54	0
293	F	Eng	9	M	53	0
294	F	Mkt	2	B	57	0
295	M	Mkt	2	B	83	1
296	F	Mkt	3	M	65	0
297	M	Eng	3	B	87	0
298	F	Mkt	1	B	44	0
299	M	Eng	8	B	75	1
300	F	Mkt	5	M	73	0

id	g	dept	exp	deg	score	h
301	F	Mkt	2	B	45	0
302	M	Eng	6	P	67	0
303	F	Mkt	8	B	67	0
304	F	Mkt	4	B	70	0
305	F	Eng	6	B	58	0
306	M	Eng	7	B	70	0
307	F	Eng	9	B	77	0
308	F	Mkt	5	B	53	0
309	M	Eng	4	B	60	0
310	M	Eng	6	M	72	1
311	F	Eng	3	M	-	0
312	F	Mkt	1	B	76	0
313	F	Eng	6	M	65	1
314	M	Eng	5	B	76	1
315	F	Eng	4	M	29	0
316	F	Mkt	5	B	77	0
317	F	Mkt	2	B	71	0
318	F	Eng	3	M	73	1
319	M	Mkt	1	B	57	0
320	M	Mkt	4	P	85	0
321	M	Eng	4	M	56	0
322	M	Eng	9	M	76	1
323	F	Eng	4	M	64	0
324	F	Mkt	2	M	42	0
325	F	Eng	2	B	73	1
326	F	Eng	4	M	66	0
327	F	Mkt	7	M	56	0
328	M	Eng	3	B	63	0
329	F	Eng	5	B	98	0
330	F	Mkt	5	B	57	0
331	F	Mkt	5	B	77	1
332	F	Mkt	4	B	63	0
333	M	Eng	3	B	67	0
334	M	Eng	3	B	77	0
335	M	Eng	7	M	76	1
336	F	Eng	8	B	70	1
337	M	Eng	4	B	53	0
338	F	Eng	5	M	68	0
339	M	Mkt	0	B	68	0
340	F	Mkt	7	B	58	0
341	F	Eng	3	M	52	0
342	F	Mkt	5	B	80	1
343	F	Mkt	4	M	51	0
344	F	Mkt	2	M	73	1
345	F	Mkt	4	B	56	0
346	M	Eng	4	M	73	0
347	M	Eng	6	M	42	0
348	M	Eng	4	B	76	1
349	F	Eng	8	P	61	1
350	M	Mkt	4	B	54	0

id	g	dept	exp	deg	score	h
351	M	Eng	2	M	89	1
352	F	Eng	5	M	65	0
353	M	Eng	4	B	68	0
354	M	Eng	4	M	67	1
355	F	Eng	6	M	74	1
356	F	Mkt	6	B	59	0
357	F	Eng	2	P	84	1
358	M	Eng	4	M	55	0
359	M	Eng	6	B	59	0
360	F	Eng	8	M	68	0
361	F	Mkt	3	M	91	0
362	M	Eng	5	M	59	1
363	F	Mkt	6	P	70	0
364	M	Eng	4	P	60	1
365	F	Eng	1	B	56	0
366	M	Mkt	7	M	69	0
367	F	Mkt	1	B	83	1
368	M	Eng	7	B	49	0
369	M	Eng	3	B	68	0
370	F	Mkt	4	B	72	0
371	M	Eng	4	M	63	1
372	M	Eng	6	M	61	1
373	F	Eng	1	B	56	1
374	M	Eng	5	M	60	0
375	M	Eng	5	B	58	1
376	F	Mkt	2	M	76	1
377	F	Mkt	3	B	58	0
378	M	Eng	2	B	69	1
379	F	Mkt	5	B	80	1
380	F	Mkt	5	B	53	1
381	M	Mkt	4	B	54	0
382	F	Mkt	2	B	66	0
383	M	Eng	6	B	59	0
384	M	Eng	4	B	77	1
385	F	Mkt	4	B	75	1
386	F	Eng	7	B	69	0
387	M	Eng	9	M	80	1
388	M	Eng	5	B	62	1
389	M	Eng	2	B	66	0
390	M	Eng	8	M	79	0
391	F	Mkt	1	M	94	0
392	F	Mkt	4	B	60	0
393	F	Eng	3	M	62	1
394	M	Eng	5	P	-	0
395	M	Eng	8	M	66	1
396	F	Eng	5	M	48	0
397	M	Eng	7	P	71	0
398	F	Mkt	6	B	65	0
399	M	Eng	6	P	67	0
400	F	Eng	4	B	77	0

id	g	dept	exp	deg	score	h
401	M	Eng	3	M	60	0
402	M	Mkt	4	B	59	0
403	M	Eng	4	B	57	0
404	M	Eng	2	B	80	1
405	F	Mkt	4	P	69	0
406	F	Mkt	4	B	34	0
407	M	Eng	4	B	77	0
408	M	Eng	6	M	71	1
409	F	Mkt	6	M	32	0
410	M	Eng	5	B	85	1
411	M	Mkt	3	M	88	0
412	M	Eng	1	M	67	0
413	M	Mkt	3	P	73	1
414	F	Eng	5	B	61	0
415	F	Mkt	5	M	60	1
416	F	Mkt	5	B	80	0
417	M	Eng	4	P	60	0
418	M	Eng	6	B	60	1
419	F	Eng	7	B	71	1
420	M	Mkt	3	P	48	1
421	F	Eng	5	P	60	0
422	F	Mkt	3	B	75	0
423	F	Eng	5	B	44	0
424	M	Eng	10	B	63	1
425	F	Eng	6	B	60	0
426	F	Eng	4	B	56	0
427	M	Eng	4	M	50	1
428	F	Eng	3	B	54	0
429	M	Eng	2	M	56	0
430	F	Mkt	8	M	55	0
431	F	Mkt	4	P	62	0
432	F	Mkt	3	M	60	0
433	F	Mkt	2	M	52	0
434	F	Mkt	3	B	69	0
435	F	Mkt	5	B	68	0
436	M	Eng	7	M	48	1
437	F	Mkt	5	B	77	0
438	M	Eng	2	B	62	0
439	M	Eng	9	B	72	1
440	F	Mkt	0	M	56	0
441	F	Eng	3	B	52	0
442	F	Mkt	5	B	65	0
443	M	Eng	7	B	53	0
444	F	Mkt	5	B	77	0
445	F	Mkt	2	M	-	0
446	M	Eng	1	M	74	1
447	M	Eng	4	P	65	1
448	M	Mkt	2	M	60	0
449	M	Eng	6	M	55	0
450	F	Eng	6	M	62	0

id	g	dept	exp	deg	score	h
451	F	Mkt	3	B	55	0
452	F	Mkt	2	M	58	0
453	M	Eng	7	M	81	1
454	M	Mkt	6	M	61	0
455	F	Mkt	8	B	74	0
456	M	Mkt	3	M	77	1
457	F	Eng	7	P	67	1
458	M	Eng	2	B	70	1
459	F	Eng	3	M	67	0
460	M	Eng	8	B	55	1
461	M	Eng	7	B	62	0
462	F	Eng	8	M	73	1
463	F	Mkt	3	B	49	0
464	F	Mkt	4	B	59	0
465	M	Eng	6	B	70	1
466	M	Eng	4	M	—	0
467	M	Mkt	1	B	66	0
468	M	Eng	10	M	61	1
469	M	Mkt	6	B	70	0
470	F	Mkt	4	B	68	0
471	M	Eng	4	B	66	1
472	F	Eng	5	M	66	0
473	F	Mkt	2	B	69	0
474	F	Mkt	5	B	58	0
475	M	Mkt	2	M	77	0
476	M	Eng	6	M	80	1
477	M	Eng	6	B	62	0
478	F	Mkt	3	M	37	0
479	F	Eng	3	B	51	0
480	F	Eng	4	P	74	1
481	M	Eng	3	B	53	1
482	M	Eng	4	B	71	0
483	F	Eng	5	M	50	0
484	M	Eng	2	M	72	1
485	M	Mkt	2	B	66	0
486	M	Eng	7	M	65	1
487	F	Eng	2	B	60	0
488	F	Eng	4	M	70	0
489	M	Mkt	6	B	51	0
490	F	Mkt	4	B	—	0
491	F	Mkt	8	B	62	0
492	F	Mkt	2	M	84	0
493	F	Mkt	3	B	41	0
494	F	Mkt	3	M	67	0
495	F	Eng	6	M	57	0
496	F	Eng	6	M	71	0
497	M	Eng	5	B	76	1
498	F	Eng	2	B	48	0
499	F	Mkt	3	B	82	0
500	F	Mkt	5	P	60	0

id	g	dept	exp	deg	score	h
501	M	Eng	4	B	62	0
502	M	Eng	8	M	56	1
503	F	Eng	7	B	—	0
504	F	Mkt	3	B	59	0
505	F	Mkt	3	B	50	0
506	F	Mkt	5	M	45	0
507	F	Eng	3	B	78	0
508	M	Eng	2	P	78	0
509	F	Eng	5	P	68	0
510	M	Eng	5	B	53	0
511	M	Eng	4	M	78	1
512	M	Eng	7	B	66	1
513	F	Eng	5	B	62	0
514	F	Mkt	4	M	55	0
515	F	Mkt	3	B	66	0
516	M	Mkt	4	M	62	0
517	F	Eng	9	M	61	1
518	M	Eng	5	M	61	0
519	F	Mkt	3	B	73	1
520	M	Eng	2	P	71	1
521	F	Mkt	4	M	81	0
522	M	Eng	3	M	61	0
523	M	Mkt	0	M	50	0
524	M	Eng	6	M	67	1
525	F	Mkt	4	B	45	0
526	F	Mkt	2	B	54	0
527	F	Mkt	3	B	77	0
528	M	Eng	4	B	84	1
529	F	Eng	4	B	70	0
530	M	Eng	6	B	67	1
531	M	Eng	3	B	61	1
532	F	Mkt	7	B	66	1
533	M	Eng	5	M	65	0
534	M	Mkt	5	B	69	0
535	F	Mkt	6	B	55	0
536	F	Mkt	3	B	67	1
537	M	Eng	7	M	48	0
538	M	Mkt	5	M	46	0
539	F	Mkt	6	M	78	0
540	M	Eng	5	B	100	1
541	F	Mkt	2	B	67	0
542	F	Mkt	9	M	65	1
543	F	Mkt	3	B	81	0
544	M	Mkt	5	B	49	0
545	M	Eng	4	B	46	0
546	M	Eng	7	B	74	1
547	M	Eng	4	B	82	1
548	M	Eng	4	P	72	1
549	F	Eng	6	M	63	1
550	F	Mkt	5	M	86	1

id	g	dept	exp	deg	score	h
551	M	Eng	5	M	59	0
552	M	Eng	6	B	63	0
553	F	Mkt	5	P	60	1
554	F	Mkt	4	M	51	0
555	M	Eng	6	M	62	0
556	F	Mkt	3	M	63	0
557	M	Eng	5	B	64	1
558	F	Eng	5	P	72	0
559	M	Eng	3	B	58	0
560	F	Mkt	4	B	80	0
561	F	Mkt	2	B	61	0
562	M	Eng	4	B	52	0
563	M	Mkt	6	B	51	0
564	F	Mkt	6	M	60	0
565	F	Eng	4	M	62	0
566	F	Mkt	4	P	70	0
567	M	Eng	5	M	—	1
568	M	Mkt	3	P	78	0
569	F	Mkt	8	P	59	0
570	M	Eng	3	M	73	1
571	M	Eng	5	B	66	0
572	M	Eng	8	B	73	1
573	M	Eng	7	B	—	0
574	M	Mkt	7	M	75	0
575	F	Mkt	4	P	53	1
576	M	Eng	6	M	91	1
577	F	Mkt	5	M	46	0
578	M	Eng	7	M	59	1
579	M	Mkt	5	M	64	0
580	M	Eng	7	B	83	0
581	F	Mkt	1	M	86	1
582	F	Mkt	4	M	53	1
583	F	Eng	5	P	79	1
584	F	Eng	9	M	48	1
585	F	Mkt	1	B	87	1
586	M	Mkt	3	P	59	0
587	F	Mkt	4	B	72	0
588	F	Mkt	3	B	68	0
589	F	Eng	4	M	55	0
590	M	Eng	4	B	66	1
591	M	Eng	5	B	70	1
592	F	Mkt	6	M	51	0
593	F	Mkt	3	M	70	0
594	F	Eng	4	B	63	0
595	F	Eng	3	B	56	0
596	F	Eng	5	M	78	1
597	F	Eng	5	M	57	0
598	M	Eng	5	B	45	0
599	M	Eng	2	B	74	1
600	M	Eng	6	M	53	0