

pandas 흐름으로 따라가는 통계

추정 · 가설 · 검증 중심 정리 (hiring_practice.csv)

각 장 = pandas 분석의 한 단계. 코드 → 실제 출력 → 개념 → 추정/가설/검증 순서로 읽습니다.

[Notes ...] 는 Statistics 1 강의노트(stats1-notes.pdf)의 해당 정의·정리 번호입니다.

장	pandas	통계 개념	추정 / 가설 / 검증
1	read_csv, info, isna	변수 종류, 결측, 측정오차, 편이	무엇을 추정할지 정하기
2	describe	평균·중앙값·최빈값, SD, RMS, 자유도, 이탈값	중심과 퍼짐의 추정
3	(x-x.mean())/x.std()	표준화, 정규근사, 백분위수	정규모형 가정 점검
4	groupby().mean()	표본비율, SE, CLT	점추정과 신뢰구간
5	crosstab, scipy.stats	z -test, χ^2 , t -test	가설검정
6	corr	산포도, 상관계수	r 추정, $\rho = 0$ 검정
7	smf.ols	회귀선, 평균의 그래프, 회귀효과	기울기 추정
8	resid	잔차, RMSE, 잔차도	오차 추정, 기울기 검정
9	sample (bootstrap)	추정량의 성질	bias, MSE, SE
10	mean, var	적률법(MoM), MLE	추정량 만들기
11	-	가설 세우기, 검정력	검증 설계
12	scipy.stats	검정 도구상자 13종	어떤 검정을 언제
13	smf.ols (다중)	다중회귀	통제 후 효과의 추정·검증

세 단어부터

- **추정 (estimation)**: 모르는 모집단 값(parameter)을 데이터로 짐작하는 것. 숫자 하나(**point estimate**)와 그 불확실성(**SE, confidence interval**)을 같이 냅니다.
- **가설 (hypothesis)**: parameter에 대한 주장. “차이 없음”을 H_0 , 보이고 싶은 것을 H_1 로 씁니다.
- **검증 (testing)**: “ H_0 가 맞다면 지금 데이터가 얼마나 이상한가”를 p-value로 재서 H_0 를 기각할지 정합니다.

모든 장에서 이 세 가지를 반복합니다. 바뀌는 것은 무엇을 추정하는가(평균, 비율, 상관, 기울기) 뿐입니다.

먼저 읽기: 분석 전체 흐름과 책 안내

네 권의 역할

표시	책 (파일)	역할
[흐름]	pandas 흐름으로 따라가는 통계 (pandas-stats-walkthrough)	기초: 평균·SD·정규·상관·회귀·검정을 pandas 순서대로
[응용]	채용 데이터로 다시 배우는 통계 (hiring-statistics-book)	응용: 통계 회귀, logistic, Bayesian, 공정성으로 결론 내기
[알고]	알고리즘으로 보는 pandas (algorithms-for-datathon)	도구: 빠르고 정확한 코드, 결정트리·greedy 보조 분석
[실습]	numpy·pandas로 직접 만드는 통계 (stats-basics-workbook)	실습: 빈칸 노트북으로 통계 공식을 직접 구현, 필요한 곳에 알고리즘 적용

※ 아래 표의 작은 색 주석이 “이 단계는 어느 책 몇 장”입니다. 예: [흐름 5] = 흐름 책 5장, [응용 6.9] = 응용 책 6.9절, [알고 4] = 알고리즘 책 4장. 0장 = 응용 책 앞의 “데이터 미리보기와 pandas 작동 원리”.

Datathon 분석 흐름: 데이터를 받은 순간부터 발표까지

단계	하는 일	대표 pandas 코드	해당 장
①	질문을 통계 질문으로	–	[응용 1] [흐름 1 추정·가설·검증 상자]
②	불러오고 구조 확인	read_csv, head, info	[응용 0.1–0.3] [흐름 1]
③	변수 분류 (결과 Y / 보호속성 A / 자격 X)	dtypes, value_counts	[응용 2] [흐름 1.1]
④	결측·이탈값 처리	isna, dropna, quantile	[응용 0.7, 2.4] [흐름 1.3, 2.3]
⑤	분포 요약 (중심, 퍼짐, 정규성)	describe, std, (x-x.mean())/x.std()	[흐름 2, 3] [응용 3.1] [알고 3 분위수] [실습 1–3]
⑥	그룹별 합계들과 신뢰구간	groupby().mean()	[응용 0.5, 3.2] [흐름 4] [알고 4 groupby 내부] [실습 4]
⑦	교란 변수 확인 (Simpson)	crosstab, groupby([a,b])	[응용 3.3] [흐름 12 ⑧]
⑧	가설검정 (차이가 우연인가)	proportions_ztest, chi2_contingency, ttest_ind	[흐름 5, 11, 12] [응용 5] [실습 5–7]
⑨	상관과 단순회귀	corr, pd.cut, smf.ols	[흐름 6–8] [알고 5 pd.cut] [실습 8–9]
⑩	통제 회귀와 interaction (핵심)	smf.ols("y ~ A + X"), A*B	[응용 0.8–0.9, 6] [흐름 13] [실습 10]
⑪	다른 방법으로 재확인	smf.logit, rng.beta, DecisionTreeClassifier	[응용 7, 8] [흐름 9 bootstrap] [실습 6, 11]
⑫	공정성 지표와 한계	rate["F"]/rate["M"], idxmin	[응용 9] [알고 8 minimax]
⑬	정리와 발표	–	[응용 9.2 결론 문장, 11 체크리스트] [흐름 14 요약] [알고 11]

※ 이론이 막히면: 추정량·MoM·MLE [흐름 9–10] [응용 4], 가설 세우기·검정력 [흐름 11], 코드가 느리면 [알고 1–2, 4]. 한 번에 돌려 보기: python3 algo_toolkit.py hiring_practice.csv (⑥⑦⑨⑪⑫ 요약).

6시간 읽기 계획 (읽기 편한 순서)

시간	무엇을	어디를	분
0:00	데이터와 pandas 감 잡기	[응용 0] 전체, [응용 1] 전체 지도	30
0:30	기초 통계 1: 요약과 분포	[흐름 1-3] (<code>describe</code> , 표준화, 정규근사)	50
1:20	기초 통계 2: 추정과 검정	[흐름 4-5] (신뢰구간, $z/\chi^2/t$)	40
2:00	휴식		10
2:10	기초 통계 3: 상관과 회귀	[흐름 6-8] (회귀 효과, RMSE, 잔차도)	50
3:00	검정 고르는 법	[흐름 12] 검정 도구상자 (표 + 관심 있는 카드만)	30
3:30	응용 1: 통제와 interaction	[응용 3, 6] + 각 장 끝 “pandas 코드” 직접 실행	50
4:20	휴식		10
4:30	응용 2: 재확인	[응용 7] logistic, [응용 8] Bayesian (8.4 “왜”는 꼭)	40
5:10	결론과 한계	[응용 9], [응용 11] 체크리스트, [알고 표지 결론표]	20
5:30	도구 실행과 발표 문장 연습	<code>algo_toolkit.py</code> 실행, [응용 9.2] 문장을 내 말로	30
(다음 날)	코드로 손에 익히기	[실습 0-12] 빈칸 노트북 (<code>stats_basics_practice.ipynb</code>)	120

※ 범위 밖 (학부 1-2학년 목표를 넘는 것): `sklearn`을 쓰는 [알고 6-7]의 결정트리와 `advanced/` 폴더의 분류 워크북은 나중에 선택으로.

※ 건너뛰어도 되는 곳 (나중에 참고용): [흐름 9-11, 13], [응용 4, 10], [알고 1-10] 본문, 모든 연습 문제. 시간이 남으면 [흐름 15] 연습 문제 1-8번부터.

※ 각 장은 새 페이지에서 시작하고, 목차의 항목을 누르면 그 쪽으로 이동합니다.

목차 (Contents)

먼저 읽기: 분석 전체 흐름과 책 안내	2
1 불러오기와 구조 파악	5
1.1 변수의 종류	5
1.2 데이터 = 확률변수의 실현값	5
1.3 측정오차와 편의	5
2 describe(): 중심과 퍼짐	6
2.1 중심: 평균, 중앙값, 최빈값	6
2.2 퍼짐: 편차, RMS, 표준편차	7
2.3 사분위수, IQR, 이탈값	7
3 표준화와 정규근사	9
3.1 단위 변환과 표준점수	9
3.2 정규분포곡선과 표준정규곡선 아래의 면적	9
3.3 자료에 대한 정규근사	9
3.4 백분위수	10
3.5 정규성 점검: Q-Q plot	10
4 groupby: 점추정과 신뢰구간	11
4.1 점추정	11
4.2 표본평균의 분포와 CLT	11
4.3 신뢰구간	11
5 가설검정	12
5.1 검정의 다섯 단계	12
5.2 예 1. 두 비율: z -test	12
5.3 예 2. 교차표: χ^2 독립성 검정	12
5.4 예 3. 두 평균: Welch t -test	13
6 corr(): 산포도와 상관계수	14
6.1 산포도	14
6.2 상관계수 구하는 법	14
6.3 성질	14
6.4 유의사항	14
7 회귀분석: 변수 간의 관계	16
7.1 평균의 그래프	16
7.2 회귀선 구하는 법	16
7.3 회귀 효과 (regression effect)	17

8	회귀분석의 오차	18
8.1	실제값과 추정치의 차이: 잔차	18
8.2	RMSE: 상관계수로 계산하기	18
8.3	σ 의 추정과 자유도 $n - 2$	18
8.4	잔차도 (residual plot)	18
9	추정량 깊이 보기	20
9.1	추정량(estimator)과 추정값(estimate)	20
9.2	표본분포를 눈으로 보기: bootstrap	20
9.3	좋은 추정량의 기준	20
10	추정량 만들기: 적률법(MoM)과 최우추정(MLE)	22
10.1	적률 (moment)	22
10.2	MoM 절차	22
10.3	MLE 절차	22
10.4	MoM vs MLE: 언제 무엇을	23
11	가설 세우기와 검증 설계	24
11.1	가설 세우는 법	24
11.2	기각 판단의 두 방법	24
11.3	신뢰구간과 검정은 같은 동전의 양면	24
11.4	두 종류의 오류와 검정력	24
11.5	검증에서 흔한 실수	25
12	검정 도구상자: 어떤 검정을 언제 쓰나	26
12.1	고르는 법: 세 가지 질문	26
①	One-sample z -test: σ 를 알 때 평균	26
②	One-sample t -test: σ 를 모를 때 평균	26
③	One-sample 비율 z -test	27
④	Two-sample 비율 z -test	27
⑤	Two-sample 평균: z / pooled t / Welch t	27
⑥	Paired t -test: 같은 대상을 두 번 잴 때	27
⑦	χ^2 적합도 검정 (goodness of fit)	28
⑧	χ^2 독립성 검정	28
⑨	Fisher's exact test	28
⑩	분산에 대한 χ^2 : 퍼짐의 추정과 검정	28
⑪	ANOVA (F -test): 세 그룹 이상의 평균	29
⑫	회귀 계수의 t -test와 F -test	29
⑬	Permutation test와 bootstrap: 공식 없이	29
12.2	검정들 사이의 관계 (외우지 않아도 되는 이유)	29

13 다중회귀: 통제된 뒤의 효과를 추정하고 검증하기	31
13.1 단순회귀에서 다중회귀로	31
13.2 계수 해석: “다른 변수를 고정하면”	31
13.3 범주형 변수와 기준 범주	31
13.4 회귀 모형의 가정과 점검	31
13.5 회귀에서의 추정 · 가설 · 검증 정리	32
13.6 예측과 예측구간	32
13.7 회귀를 넘어서	32
14 한 장 요약	33
15 연습 문제	34
16 풀이	35

1 불리오기와 구조 파악

```
df = pd.read_csv("hiring_practice.csv")
df.shape                                # (600, 7)
df.dtypes; df.isna().sum()             # test_score만 결측 18개
```

1.1 변수의 종류

열	종류	쓸 수 있는 요약
gender, hired	binary (0/1)	비율
department	nominal (순서 없는 범주)	빈도, 최빈값
degree	ordinal (순서 있는 범주)	빈도, 최빈값, 중앙값
years_experience	discrete (정수)	평균, 중앙값, SD
test_score	continuous	평균, 중앙값, SD, 분포
applicant_id	identifier	쓰지 않음

※ 종류가 곧 방법을 정합니다. 평균은 수량에만, 비율은 범주에만 의미가 있습니다.

1.2 데이터 = 확률변수의 실현값

강의노트의 출발점: 데이터 $x_1, \dots, x_n$ 은 확률변수 $X_1, \dots, X_n$ 의 **realization** 이고, 보통 IID (독립, 같은 분포)라고 가정합니다. [Notes §1.4]

※ 그래서 “표본에서 계산한 값”은 표본이 바뀌면 달라지는 확률변수이고, 이 흔들림을 제는 것이 추정·검증의 핵심입니다.

1.3 측정오차와 편의

- **측정오차 (measurement error):** 관측값 = 참값 + 오차. test_score는 “실력”을 시험 한 번으로 잰 값이라 우연 오차가 섞여 있습니다.
 - ※ 우연 오차는 평균에서는 상쇄되지만 SD는 키우고, 다른 변수와의 상관 r 과 회귀 기울기를 0 쪽으로 줄입니다 (attenuation).
- **편의 (bias):** 우연이 아니라 한쪽으로 일관되게 틀리는 것. 두 가지 의미로 쓰입니다.
 - 자료의 편의: 채점 기준이 한 집단에 불리하거나, 특정 집단만 지원하는 경우 (**selection bias**). 표본을 늘려도 사라지지 않습니다.
 - 추정량의 편의: $\text{bias}(T) = \mathbb{E}[T] - \theta$. [Notes Def 7.2] 2장의 $n - 1$ 이 여기서 나옵니다. [→ 9장에서 자세히]
- **결측 (missing):** 18행 (3%). 결측 18명 중 합격자 4명으로 전체 합격률과 비슷하므로 dropna()로 제외해도 큰 편의는 없다고 판단합니다.

추정 · 가설 · 검증

여기서는 아직 계산하지 않고 무엇을 추정·검증할지를 정합니다.

- 추정 대상: 성별 합격 확률 p_M, p_F , 그 차이 $p_M - p_F$, 점수가 합격에 주는 효과(기울기).
- 가설: $H_0 : p_M = p_F$ (성별과 합격은 무관), H_0 : 점수 평균은 성별로 같다.

2 describe(): 중심과 퍼짐

```
df[["years_experience", "test_score", "hired"]].describe()
```

	years_experience	test_score	hired
count	600	582	600
mean	4.455	65.235	0.322
std	1.962	11.657	0.468
min	0	29	0
25%	3	58	0
50%	4	65	0
75%	6	73	1
max	11	100	1

※ hired의 mean 0.322 = 합격률 32.2%. 0/1 변수의 평균은 비율입니다.

2.1 중심: 평균, 중앙값, 최빈값

- **Mean** $\bar{x} = \frac{1}{n} \sum x_i$ [Notes Def 2.3]
- **Median**: 정렬했을 때 가운데 값 (**order statistics** $x_{(1)} \leq \dots \leq x_{(n)}$ 의 가운데) [Notes Def 2.1, 2.4]
- **Mode**: 가장 자주 나오는 값. `df.col.mode()`

	평균	중앙값	최빈값
test_score	65.2	65	60
years_experience	4.46	4	4
degree	–	(Bachelor)	Bachelor

언제 무엇을 쓰나

	장점	이럴 때
평균	모든 값을 사용, 합치기 쉬움 (두 집단 평균 → 전체 평균)	대칭 분포, 이후 <i>t</i> -test·회귀에 쓸 때
중앙값	극단값에 둔감 (robust)	소득, 집값처럼 한쪽으로 긴 분포, 이 탈값이 있을 때
최빈값	범주형에도 정의됨	nominal 변수, “가장 흔한 유형”

※ 노트의 예: (3, 1, 5, 9, 0, -1)에서 -1을 -1000으로 바꾸면 평균은 2.83 → -163.7, 중앙값은 2 그대로. [Notes §2.2]

※ 손실함수로 보면: 평균은 $\sum (x_i - c)^2$, 중앙값은 $\sum |x_i - c|$, 최빈값은 “틀린 개수”를 최소화하는 *c*입니다 (문제지 주제).

※ 평균 ≈ 중앙값이면 대칭, 평균 > 중앙값이면 오른쪽 꼬리. test_score는 65.2 vs 65로 거의 대칭, 경력은 4.46 vs 4로 약간 오른쪽 꼬리 (skewness 0.29).

2.2 퍼짐: 편차, RMS, 표준편차

1단계: 편차 $d_i = x_i - \bar{x}$. 평균에서 얼마나 떨어졌나. 그런데 $\sum d_i = 0$ 이라 그냥 평균내면 항상 0입니다.

2단계: RMS (제곱근-평균-제곱, root-mean-square). 부호를 없애는 표준 방법:

$$\text{RMS}(a_1, \dots, a_n) = \sqrt{\frac{1}{n} \sum a_i^2} \quad (\text{제곱} \rightarrow \text{평균} \rightarrow \text{제곱근, 오른쪽부터 읽기}).$$

※ RMS는 “전형적인 크기”입니다. 예: 0, 5, -8, 7, -3의 $\text{RMS} = \sqrt{147/5} \approx 5.4$.

3단계: 표준편차 = 편차의 RMS.

$$\text{SD} = \text{RMS}(d_1, \dots, d_n) = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2}.$$

뜻: “각 값이 평균에서 전형적으로 얼마나 떨어져 있나”. `test_score`의 $\text{SD} \approx 11.6$ 점.

4단계: 표본분산과 자유도. 노트와 pandas의 기본값은 n 대신 $n-1$ 로 나눕니다. [Notes Def 2.5]

$$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2, \quad s = \sqrt{s^2}.$$

pandas	분모	test_score
<code>s.std(ddof=0)</code>	n (= 편차의 RMS)	11.647
<code>s.std()</code> (기본, <code>ddof=1</code>)	$n-1$	11.657

※ numpy `np.std`는 기본이 `ddof=0`, pandas는 `ddof=1`. 결과가 미세하게 다르며 이 때문입니다.

왜 $n-1$ 인가: 자유도와 편차

- 자유도 (degrees of freedom): 편차 $d_1, \dots, d_n$ 은 $\sum d_i = 0$ 이라는 제약이 하나 있어서, $n-1$ 개를 정하면 마지막 하나는 자동으로 정해집니다. “자유롭게 움직이는 값”이 $n-1$ 개.
- 그래서 n 으로 나누면 분산을 체계적으로 작게 추정합니다: $\mathbb{E}[\frac{1}{n} \sum (X_i - \bar{X})^2] = \frac{n-1}{n} \sigma^2$ (편의 있음). $n-1$ 로 나누면 $\mathbb{E}[S^2] = \sigma^2$ (unbiased). [Notes Def 7.2]
- 정규분포에서는 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. 자유도 $n-1$ 이 분포 이름에 그대로 들어갑니다. [Notes Thm 8.12]
- 같은 원리로 회귀에서는 α, β 두 개를 추정하므로 잔차의 자유도가 $n-2$ 입니다 (8장). [Notes Prop 11.13]

※ $n=582$ 에서는 11.647 vs 11.657로 차이가 무시할 만합니다. n 이 작을 때만 중요합니다.


2.3 사분위수, IQR, 이탈값

- Quantile: p -분위수 = 자료의 100

%가 그 아래에 있는 값. [Notes Def 2.7]
- Quartiles $Q_1, Q_2, Q_3 = 25, 50, 75\%$ 분위수. **IQR** = $Q_3 - Q_1$ (가운데 50%의 폭). [Notes Def 2.9]
- 이탈값 (outlier) 규칙 (boxplot의 수염): $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$ 밖.

```
q1, q3 = s.quantile([.25, .75]); iqr = q3 - q1 # 58, 73, 15
s[(s < q1-1.5*iqr) | (s > q3+1.5*iqr)] # 울타리 35.5, 95.5
```

결과: 29, 32, 33, 34, 35, 35, 35 (아래), 98, 100, 100 (위) — 10명. 경력은 11년 한 명.



이탈값을 만나면

1. 먼저 오류인지 확인 (입력 실수, 단위 실수). 오류면 고치거나 제거.
2. 진짜 값이면 지우지 않는다. 100점은 가능한 점수입니다. 대신 이탈값을 빼고도 결론이 같은지 확인 (**sensitivity check**).
3. 영향 비교: 평균·SD·상관·회귀는 이탈값에 민감, 중앙값·IQR은 둔감.

※ 노트 Anscombe's quartet의 3번 자료: 한 점 때문에 회귀선이 크게 틀어짐. [\[Notes Ex 11.15\]](#)

추정 · 가설 · 검증

- 추정: 모집단 평균 μ 의 추정량 $\bar{X}$ (65.24), 모집단 SD σ 의 추정량 S (11.66).
- 추정량 평가: $MSE = Var + bias^2$. [\[Notes Prop 7.4\]](#) $\bar{X}$ 는 unbiased이고 $Var(\bar{X}) = \sigma^2/n$ 이므로 $MSE = \sigma^2/n$. [\[Notes Ex 7.5\]](#)
- SE: $SE(\bar{X}) = s/\sqrt{n} = 11.66/\sqrt{582} = 0.48$ 점. “평균 65.2점은 ± 0.5 점 정도 흔들린다.”

3 표준화와 정규근사

3.1 단위 변환과 표준점수

```
z = (s - s.mean()) / s.std()
```

Standard units (z-score): $z = \frac{x - \bar{x}}{SD}$ = “평균보다 SD 몇 개만큼 위/아래인가”.

- 85점: $z = (85 - 65.24)/11.66 = 1.70$. 평균보다 1.7 SD 위.
- 단위 변환 $y = ax + b$ 의 효과: 평균 $\rightarrow a\bar{x} + b$, SD $\rightarrow |a| SD$ (더하기는 SD에 영향 없음). [\[Notes Lemma 8.6\]](#)
 ※ 점수를 10으로 나누면 평균 6.52, SD 1.17. 하지만 z-score는 그대로입니다. 그래서 z 는 단위와 무관한 비교 척도이고, 상관계수(6장)도 같은 이유로 단위와 무관합니다.
- $X \sim N(\mu, \sigma^2) \iff Z = (X - \mu)/\sigma \sim N(0, 1)$. [\[Notes Cor 8.7\]](#)

3.2 정규분포곡선과 표준정규곡선 아래의 면적

표준정규곡선 $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ 는 0에서 대칭인 종 모양이고, 전체 면적은 1입니다. 면적 = 확률 = 비율.

구하는 것	식	Python (from scipy.stats import norm)
z 아래 면적	$\Phi(z)$	<code>norm.cdf(z)</code>
z 위 면적	$1 - \Phi(z)$	<code>norm.sf(z)</code>
a 와 b 사이	$\Phi(b) - \Phi(a)$	<code>norm.cdf(b)-norm.cdf(a)</code>
$-z$ 와 z 사이	$2\Phi(z) - 1$	<code>norm.cdf(z)-norm.cdf(-z)</code>
면적 p 가 되는 z (역)	$\Phi^{-1}(p)$	<code>norm.ppf(p)</code>

※ R의 `pnorm`, `qnorm`과 같습니다. 노트 표기 z_β : $P(Z \geq z_\beta) = \beta$, 예: $z_{0.025} = 1.96$. [\[Notes §9.2\]](#)

※ 손으로 할 때 요령: 그림을 먼저 그리고, 대칭($\Phi(-z) = 1 - \Phi(z)$)을 써서 표에 있는 형태로 바꿉니다.

3.3 자료에 대한 정규근사

방법: 자료가 대략 종 모양이면, 평균과 SD만으로 비율을 근사합니다. (1) 경계값을 z 로 바꾸고 (2) 정규곡선 아래 면적을 구합니다.

test_score	실제 비율	정규근사
평균 ± 1 SD 안	68.2%	68.3%
평균 ± 2 SD 안	95.5%	95.4%
평균 ± 3 SD 안	99.8%	99.7%
80점 이상 ($z = 1.27$)	10.7%	10.3%
50-70점	59.8%	56.3%

※ 68-95-99.7 규칙이 거의 정확히 맞습니다. 50-70점에서 차이가 나는 이유: 점수가 정수라서 경계값 50, 70 자체에 사람이 몰려 있음. 이산 자료는 경계를 49.5, 70.5로 잡으면 더 정확합니다 (continuity correction).

3.4 백분위수

Percentile: p 번째 백분위수 = 자료의 $p\%$ 가 그 아래에 있는 값.

```
s.quantile(0.9)
```

실제: 80

```
s.mean() + norm.ppf(0.9) * s.std()
```


정규근사: $65.24 + 1.28 \times 11.66 = 80.2$

백분위	10	25 (Q_1)	50	75 (Q_3)	90	95
실제	51	58	65	73	80	85
정규근사	50.3	57.4	65.2	73.1	80.2	84.4

※ 거꾸로: 85점은 몇 백분위? $\Phi(1.70) = 0.955$, 실제 95.7%. 즉 상위 약 4.5%.

※ 정규분포에서 $IQR \approx 1.35 SD$. 여기서 $15/11.66 = 1.29$ 로 비슷합니다.

3.5 정규성 점검: Q-Q plot



자료의 분위수를 정규분포 분위수에 대해 그립니다. 직선이면 정규근사가 적절합니다. [Notes §5.5–5.6]

- 양 끝이 직선보다 바깥으로 휨: 꼬리가 두꺼움 (heavy tails)
- 안쪽으로 휨: 꼬리가 얇음
- 한쪽만 휨: 비대칭 (skew)

※ test_score는 거의 직선이고, 끝의 계단 모양은 정수 점수 때문입니다.

추정 · 가설 · 검증

- 가설: H_0 : test_score는 정규분포를 따른다.
- 검증: Q-Q plot (시각적) + Shapiro-Wilk (`scipy.stats.shapiro`) $p = 0.47 \Rightarrow$ 기각하지 않음.
- 의미: 정규 가정을 쓰는 t -test 등을 써도 무리가 없습니다. 더 중요한 점: 표본이 크면 CLT 덕분에 평균은 원자료가 정규이 아니어도 근사적으로 정규입니다 (4장).

4 groupby: 점추정과 신뢰구간

```
g = df.groupby("gender")["hired"].agg(["mean", "count"])
```

	n	합계	$\hat{p}$	$SE = \sqrt{\hat{p}(1 - \hat{p})/n}$
F	313	68	0.217	0.023
M	287	125	0.436	0.029

4.1 점추정

각 지원자 $Y_i \sim \text{Bernoulli}(p)$. 추정량 $\hat{p} = \bar{Y}$ (표본비율).

- MoM: $\mathbb{E}[Y] = p$ 를 $\bar{Y}$ 로 바꿔 놓으면 $\hat{p} = \bar{Y}$. [Notes §4] [→ 10장에서 자세히]
- MLE도 같은 답. [Notes §6]
- Unbiased: $\mathbb{E}[\hat{p}] = p$. $\text{Var}(\hat{p}) = p(1 - p)/n$.

4.2 표본평균의 분포와 CLT

같은 채용 과정에서 다른 313명의 여성이 지원했다면 $\hat{p}_F$ 는 조금 달랐을 것입니다. 이 “표본마다 달라지는 분포”가 **sampling distribution**입니다. [Notes §7.1]

$$\text{CLT: } \bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right) \quad (n \text{이 크면, 원래 분포와 무관}).$$

※ 정규자료면 정확히 $\bar{X} \sim N(\mu, \sigma^2/n)$. [Notes Cor 8.9] 아니면 CLT로 근사. [Notes §7.4]

※ SD vs SE: SD는 개인들이 얼마나 퍼져 있나 (0.41), SE는 추정값이 표본마다 얼마나 흔들리나 (0.023). $SE = SD/\sqrt{n}$.

4.3 신뢰구간

$$\hat{p} \pm 1.96 SE \quad \implies \quad F : [0.172, 0.263], \quad M : [0.378, 0.493].$$

두 그룹 차이: $\hat{p}_M - \hat{p}_F = 0.218$, $SE = \sqrt{0.023^2 + 0.029^2} = 0.037$, 95% CI [0.145, 0.292].

※ 1.96은 $z_{0.025}$: 표준정규에서 가운데 95% 면적의 경계 (3장). [Notes §9.4]

※ 해석: “이 방법으로 구간을 만들면 100번 중 약 95번은 진짜 p 를 포함한다.” 진짜 p 가 이 구간에 있을 확률이 95%라는 뜻은 아닙니다. [Notes §9.1]

※ 평균일 때 σ 를 모르고 s 를 쓰면 1.96 대신 $t_{n-1, 0.025}$ 를 씁니다. [Notes Thm 8.16, §9.3]

추정 · 가설 · 검증

- 추정: $p_M - p_F$ 의 점추정 0.218, 95% CI [0.145, 0.292].
- CI로 하는 검증: 구간에 0이 없으므로 $H_0 : p_M = p_F$ 는 5% 수준에서 기각됩니다. (CI와 양측검정은 같은 정보를 다른 형태로 보여 줍니다.)

5 가설검정

5.1 검정의 다섯 단계

[Notes §10.1] [→ 11장에서 자세히]

1. 가설: H_0 (차이 없음) vs H_1 (차이 있음).
2. 유의수준 α (보통 0.05)를 미리 정함.
3. 검정통계량: $\frac{\text{추정값} - H_0\text{에서의 값}}{\text{SE}}$. 거의 모든 검정이 이 모양입니다.
4. H_0 에서의 분포 ($N(0, 1)$, t , χ^2)로 p-value 계산.
5. $p < \alpha$ 이면 H_0 기각.

	H_0 참	H_0 거짓
기각	Type I error (α)	맞음 (power)
기각 안 함	맞음	Type II error

※ p-value = $P(\text{지금만큼 극단적인 결과} \mid H_0)$. “ H_0 가 참일 확률”이 아닙니다. 또 $p > 0.05$ 는 “차이 없음”의 증명이 아니라 “증거 부족”입니다.

5.2 예 1. 두 비율: z -test

가설 $H_0: p_M = p_F$, $H_1: p_M \neq p_F$.

통계량 H_0 에서는 두 확률이 같으므로 합친 비율 $\hat{p} = 193/600 = 0.322$ 로 SE를 계산:

$$z = \frac{0.436 - 0.217}{\sqrt{0.322 \cdot 0.678 (1/287 + 1/313)}} = \frac{0.218}{0.0382} = 5.72.$$

검증 $p = 2P(Z > 5.72) = 1.1 \times 10^{-8} < 0.05 \Rightarrow$ 기각.

```
from statsmodels.stats.proportion import proportions_ztest
proportions_ztest([125, 68], [287, 313]) # (5.72, 1.1e-08)
```

5.3 예 2. 교차표: χ^2 독립성 검정

```
ct = pd.crosstab(df.gender, df.hired)
chi2, p, dof, expected = scipy.stats.chi2_contingency(ct, correction=False)
```

	관측 0	관측 1	기대 0	기대 1
F	245	68	212.3	100.7
M	162	125	194.7	92.3

기대빈도 = (행 합)(열 합)/ n = “독립이라면 나왔을 숫자”. $\chi^2 = \sum \frac{(O-E)^2}{E} = 32.70$, 자유도 $(2-1)(2-1) = 1$, $p = 1.1 \times 10^{-8}$.

※ $\chi^2(r)$ = 표준정규 r 개의 제곱합. [Notes Def 8.10] 그래서 2×2 표에서는 $\chi^2 = z^2$ ($5.72^2 = 32.7$)입니다.

5.4 예 3. 두 평균: Welch t -test

질문: 남성이 원래 점수가 높아서 많이 붙은 것일까?

가설 $H_0: \mu_M = \mu_F$ (점수 평균이 같다).

$$t = \frac{65.79 - 64.73}{\sqrt{11.39^2/279 + 11.89^2/303}} = \frac{1.06}{0.97} = 1.10, \quad p = 0.27.$$

검증 기각하지 않음. 점수 차이에 대한 증거가 없으므로 “점수 때문”이라는 설명은 약합니다.

```
scipy.stats.ttest_ind(male_scores, female_scores, equal_var=False)
```

※ 분산이 같다고 가정하면 pooled t , 아니면 Welch. 기본은 Welch가 안전합니다. [Notes §10.5.2–10.5.3] [[→ 12장 검정 도구상자에서 자세히](#)]

추정 · 가설 · 검증

질문	H_0	통계량	결론
합격률이 성별로 다른가	$p_M = p_F$	$z = 5.72$	기각 ($p \approx 10^{-8}$)
성별과 합격이 독립인가	독립	$\chi^2 = 32.7$	기각
점수가 성별로 다른가	$\mu_M = \mu_F$	$t = 1.10$	기각 못 함 ($p = 0.27$)

6 corr(): 산포도와 상관계수

```
df[["years_experience", "test_score", "hired"]].corr()
```

	experience	score	hired
experience	1	0.008	0.197
score	0.008	1	0.247
hired	0.197	0.247	1

6.1 산포도

두 수치 변수의 관계는 먼저 **scatter plot**으로 봅니다 (`df.plot.scatter("test_score", "hired")`). 볼 것: 방향(양/음), 형태(직선/곡선), 강도(점이 얼마나 모여 있나), 이탈값. 7장 그림 왼쪽이 `test_score-hired`의 산포도입니다.

6.2 상관계수 구하는 법

$$r = \text{평균}[(x \text{의 } z\text{-score}) \times (y \text{의 } z\text{-score})] = \frac{1}{n} \sum_i \frac{x_i - \bar{x}}{SD_x} \cdot \frac{y_i - \bar{y}}{SD_y}.$$

1. 두 변수를 각각 표준점수로 바꾼다 (SD는 n 으로 나눈 것).
2. 짝끼리 곱한다. 둘 다 평균보다 크거나 둘 다 작으면 +, 엇갈리면 -.
3. 평균낸다.

```
zx = (x - x.mean())/x.std(ddof=0); zy = (y - y.mean())/y.std(ddof=0)
(zx * zy).mean() # 0.2465 = df.corr()의 값
```

※ 노트에는 상관계수가 따로 정의되어 있지 않지만, 회귀 기울기 $\hat{\beta} = \frac{\text{cov}}{\text{var}}$ 에 같은 재료가 쓰입니다. $r = \frac{\text{cov}(x,y)}{SD_x SD_y}$. [Notes Remark 11.5]

6.3 성질

- $-1 \leq r \leq 1$. ± 1 이면 모든 점이 한 직선 위.
- 단위와 무관: x 를 $ax + b$ ($a > 0$)로 바꿔도 r 그대로 (점수를 10으로 나눠도 0.2465). $a < 0$ 이면 부호만 바뀐다.
- 대칭: $r(x, y) = r(y, x)$.
- 0/1 변수와의 상관도 같은 공식 (**point-biserial correlation**).

6.4 유의사항

- 직선 관계만 쟀다. $r \approx 0$ 이어도 곡선 관계는 강할 수 있습니다 (Anscombe 2번 자료). 반드시 산포도를 먼저. [Notes Ex 11.15]
- 이탈값 한 점이 r 을 크게 바꿀 수 있습니다.
- 상관은 인과가 아니다. 제3의 변수(confounder)가 둘 다를 움직일 수 있습니다.
- 평균끼리의 상관 (부서별 평균 등)은 개인 단위 상관보다 훨씬 강하게 나옵니다 (**ecological correlation**).

- 범위 제한: 점수 상위권만 뽑아서 보면 r 이 작아집니다.
- 측정오차는 r 을 0 쪽으로 줄입니다 (1장).

※ experience-score $r = 0.008$: 두 자격 변수는 사실상 무관합니다. 그래서 회귀에 같이 넣어도 서로 효과를 빼앗지 않습니다.

추정 · 가설 · 검증

- 추정: 모집단 상관 ρ 의 추정값 $r = 0.247$ ($n = 582$).
- 가설: $H_0 : \rho = 0$ (점수와 합격은 선형으로 무관).
- 검증: $t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0.247\sqrt{580}}{\sqrt{1-0.061}} = 6.13$, 자유도 $n - 2$, $p = 1.7 \times 10^{-9} \Rightarrow$ 기각.
(`scipy.stats.pearsonr`)
- experience-score: $r = 0.008$, $p = 0.85 \Rightarrow$ 기각 못 함.

※ 이 t 는 8장의 기울기 t 와 정확히 같은 값입니다. “상관이 0”과 “기울기가 0”은 같은 가설이기 때문입니다.

7 회귀분석: 변수 간의 관계

7.1 평균의 그래프


“점수가 x 인 사람들의 평균 합격률”을 점수 구간별로 구해 이은 것이 **graph of averages**입니다.

```
bins = pd.cut(d.test_score, [0,40,50,55,60,65,70,75,80,90,101])
d.groupby(bins)["hired"].mean()
```

점수	≤40	40-50	50-55	55-60	60-65	65-70	70-75	75-80	80-90	90+
n	12	42	55	101	83	103	72	60	47	7
합격률	.00	.21	.15	.26	.31	.30	.46	.43	.60	.29

회귀선 = 평균의 그래프를 직선으로 다듬은 것. 평균의 그래프가 대략 직선이면 회귀선을 써도 됩니다.

※ 90점 이상의 .29는 7명뿐이라 매우 불안정합니다. 표본이 작은 구간은 믿지 마세요.



7.2 회귀선 구하는 법

모형: $Y_i = \alpha + \beta x_i + \sigma Z_i$, $\mathbb{E}[Z_i] = 0$, $\text{Var}(Z_i) = 1$. [Notes Def 11.1]

최소제곱 (잔차 제곱합 최소화)의 해 [Notes Thm 11.4]:

$$\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = r \cdot \frac{SD_y}{SD_x}, \quad \hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}.$$

기억하는 법: x 가 1 SD 늘면, y 는 평균적으로 r SD만큼 늘어난다. 회귀선은 점 $(\bar{x}, \bar{y})$ 를 지납니다.

```
smf.ols("hired ~ test_score", data=d).fit().params
```

손계산: $\bar{x} = 65.24$, $SD_x = 11.65$, $\bar{y} = 0.325$, $SD_y = 0.468$, $r = 0.247$.

$$\hat{\beta} = 0.247 \times \frac{0.468}{11.65} = 0.0099, \quad \hat{\alpha} = 0.325 - 0.0099 \times 65.24 = -0.322.$$

해석: 점수 1점당 합격 확률 +1.0%p, 10점당 +9.9%p. 예측: 80점 $\rightarrow$ 0.47, 50점 $\rightarrow$ 0.17.

※ 30점 $\rightarrow$ -0.02: 직선은 0 아래로 내려갑니다. 0/1 결과에 직선을 쓰는 LPM의 한계이고, 그래서 logistic regression을 보조로 씁니다 (이전 책 §7). 또한 자료 범위 밖으로 예측하는 **extrapolation**은 위험합니다.


7.3 회귀 효과 (regression effect)

기울기를 SD 단위로 보면 r 입니다. $|r| < 1$ 이므로, x 에서 극단적인 사람의 y 예측값은 덜 극단적입니다. 이것이 **regression to the mean**입니다.

y 를 x 로 예측 (hired ~ score): 점수가 평균보다 2 SD 위 (88.5점)인 사람의 예측 합격률은 y 평균보다 $r \times 2 = 0.49$ SD 위, 즉 $0.325 + 0.49 \times 0.468 = 0.56$. 2 SD가 아니라 0.49 SD.

x 를 y 로 예측 (score ~ hired): 합격자 ($y = 1$, $z_y = 1.44$)의 예측 점수는 평균보다 $r \times 1.44 = 0.36$ SD 위, 즉 $65.24 + 0.36 \times 11.65 = 69.4$ 점. 실제 합격자 평균도 69.4점입니다.

※ 정확히 일치하는 이유: 설명변수가 0/1이면 회귀 예측값은 그 그룹의 평균입니다 (이전 책 연습문제 6).



두 개의 회귀선 (표준화한 자료, $r = 0.5$ 예시):

- **SD line** (점선, 기울기 1): 구름의 장축. 눈으로 보면 이 선이 “맞는 선” 같지만 예측선이 아닙니다.
- **y on x** (빨강): 기울기 r . SD line보다 낮습니다.
- **x on y** (파랑): $x = r y$. SD line보다 셉니다.

원래 단위에서 기울기 곱: $\hat{\beta}_{y|x} \cdot \hat{\beta}_{x|y} = r \frac{SD_y}{SD_x} \cdot r \frac{SD_x}{SD_y} = r^2$. 여기서는 $0.0099 \times 6.13 = 0.061 = 0.247^2$.

※ 그래서 y 를 x 로 예측한 식을 거꾸로 풀어 x 를 예측하면 틀립니다. 방향마다 회귀를 따로 해야 합니다.

회귀의 오류 (regression fallacy)

시험 1등이 다음 시험에서 성적이 떨어지는 것은 대개 “자만해서”가 아니라 회귀 효과입니다. 1 등에는 실력 + 행운(측정오차)이 섞여 있고, 다음 시험에서는 행운이 반복되지 않습니다. 회귀 효과에 인과적 설명을 붙이는 것이 **regression fallacy**입니다.

추정 · 가설 · 검증

- 추정: $\hat{\beta} = 0.0099$ (점수 1점당 합격 확률 +1%p).
- 추정량의 성질: $\hat{\alpha}, \hat{\beta}$ 는 unbiased이고 $\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$. [Notes Thm 11.6]
 ※ x 가 넓게 퍼져 있을수록 기울기를 정확하게 추정합니다.
- 검정은 오차 σ 를 추정한 뒤에 할 수 있습니다 → 8장.

8 회귀분석의 오차

8.1 실제값과 추정치의 차이: 잔차

```
fit = smf.ols("hired ~ test_score", data=d).fit()
fit.fittedvalues      # 추정치  $\hat{y}_i$ 
fit.resid             # 잔차  $e_i = y_i - \hat{y}_i$ 
```

- **Fitted value** $\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$. [Notes Def 11.10]
- **Error** $Y_i - \alpha - \beta x_i$: 진짜 직선에서의 차이. 관측 불가.
Residual $e_i = y_i - \hat{y}_i$: 추정된 직선에서의 차이. 관측 가능, error의 추정치. [Notes Def 11.11]
- 잔차는 항상 $\sum e_i = 0$ 이고 x 와 상관이 0입니다 (최소제곱의 normal equation).

8.2 RMSE: 상관계수로 계산하기

회귀선의 전형적인 오차 크기 = 잔차의 RMS:

$$\text{RMSE} = \text{RMS}(e_1, \dots, e_n) = \sqrt{1 - r^2} \cdot \text{SD}_y.$$

직접 계산 <code>np.sqrt((fit.resid**2).mean())</code>	0.4538
공식 $\sqrt{1 - 0.247^2} \times 0.468$	0.4538

해석:

- $r = 0$: $\text{RMSE} = \text{SD}_y$. x 가 아무 도움이 안 되므로 그냥 평균으로 예측하는 것과 같음.
- $r = \pm 1$: $\text{RMSE} = 0$. 완벽한 예측.
- 여기서는 $\sqrt{1 - 0.061} = 0.97$: 점수를 알아도 예측 오차가 3%만 줄어듭니다. 점수는 유의한 변수지만 혼자서는 합격을 잘 예측하지 못합니다.

※ $r^2 = 0.061$ 은 R^2 (설명된 분산 비율)와 같습니다. 유의성(p)과 예측력(R^2)은 다른 질문입니다.

※ 증명 스케치: $\sum e_i^2 = \sum (y_i - \bar{y})^2 - \hat{\beta}^2 \sum (x_i - \bar{x})^2$ [Notes Prop 11.13 증명]에 $\hat{\beta} = r\text{SD}_y/\text{SD}_x$ 를 넣으면 $n\text{SD}_y^2(1 - r^2)$.

※ 사용법: 정규 모양이면 회귀선 ± 1 RMSE 안에 약 68%, ± 2 RMSE 안에 약 95%의 점이 들어갑니다 (3장의 정규근사를 잔차에 적용).

8.3 σ 의 추정과 자유도 $n - 2$

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n - 2} = \frac{1}{n - 2} \sum e_i^2 \quad (\text{unbiased}). \quad [\text{Notes Prop 11.13}]$$

α, β 두 개를 데이터로 추정했기 때문에 자유도가 2 줄어듭니다 (2장의 $n - 1$ 과 같은 원리). 여기서 $\hat{\sigma} = 0.4546$ vs RMSE 0.4538.

8.4 잔차도 (residual plot)

x 축에 $\hat{y}$ (또는 x), y 축에 잔차를 그립니다 (7장 그림 오른쪽). 좋은 잔차도 = 0 주위에 아무 패턴 없이 고르게 흩어진 때. [Notes Ex 11.14]

보이는 모양	의미
패턴 없는 수평 띠	직선 모형 적절
곡선 (U자 등)	관계가 비선형 → 변수 변환, 다항식
부채꼴 (점점 넓어짐)	분산이 x 에 따라 다름 (heteroskedasticity) → robust SE
멀리 떨어진 점	이탈값, 영향점 → 빼고 다시 확인

※ 우리 그림의 두 줄 띠는 y 가 0/1이라 생기는 모양 ($y = 1$ 이면 $1 - \hat{y}$, $y = 0$ 이면 $-\hat{y}$)이고, LPM에서는 정상입니다. 대신 분산이 $\hat{y}(1 - \hat{y})$ 로 변하므로 robust SE를 씁니다.

※ 요약통계(평균, SD, r)가 같아도 그림은 전혀 다를 수 있습니다 (Anscombe). 숫자만 보지 말고 항상 산포도와 잔차도를 그립니다. [Notes Ex 11.15]

추정 · 가설 · 검증

- 가설: $H_0 : \beta = 0$ (점수는 합격 확률과 선형 관계가 없다).
- 통계량: $SE(\hat{\beta}) = \hat{\sigma} / \sqrt{\sum (x_i - \bar{x})^2} = 0.00162$, $t = \hat{\beta} / SE = 0.00991 / 0.00162 = 6.13$. 정규 오차 가정에서 $t \sim t(n - 2)$. [Notes Thm 11.18]
- 검증: $p = 1.7 \times 10^{-9} \Rightarrow$ 기각. 95% CI [0.0067, 0.0131] (0 미포함).
- 6장의 r 검정과 같은 $t = 6.13$ 입니다.

※ [→ 13장에서 자세히] 이 틀이 그대로 다중회귀로 확장됩니다: `hired ~ C(gender) + test_score + ...`에서 성별 계수의 t -test가 “점수 등을 통제해도 성별 차이가 있는가”의 검증입니다 (이전 책 §6).

9 추정량 깊이 보기

[↑ 2장 SE, 4장 점추정 보강]

9.1 추정량(estimator)과 추정값(estimate)

- **Estimator** $\hat{\theta} = T(X_1, \dots, X_n)$: 데이터를 넣으면 숫자를 내는 규칙(함수). 확률변수입니다.
- **Estimate** $T(x_1, \dots, x_n)$: 실제 데이터를 넣어 나온 숫자. [Notes Def 3.6]

※ pandas로 비유하면: 추정량 = `lambda d: d.groupby("gender").hired.mean()`, 추정값 = 그 함수를 `df`에 적용한 결과 0.217.

※ 모르는 값의 함수 $g(\theta)$ 도 $g(\hat{\theta})$ 로 추정합니다. [Notes Ex 3.7] 예: 여성의 합격 odds $p/(1-p)$ 의 추정값 = $0.217/0.783 = 0.278$. MLE는 이렇게 변환해도 여전히 MLE입니다 (invariance). [Notes §6.3]

9.2 표본분포를 눈으로 보기: bootstrap

추정량이 확률변수라는 것을 pandas로 직접 확인할 수 있습니다. 데이터에서 복원추출로 같은 크기의 표본을 계속 다시 뽑아, 그때마다 추정값을 계산합니다.

```
diffs = []
for b in range(2000):
    bs = df.sample(frac=1, replace=True)
    m = bs.groupby("gender").hired.mean()
    diffs.append(m["M"] - m["F"])
np.std(diffs) # 0.0385
np.percentile(diffs, [2.5, 97.5]) # [0.144, 0.293]
```

$\hat{p}_M - \hat{p}_F$	SE	95% 구간
공식 (4장)	0.0374	[0.145, 0.292]
Bootstrap (2000회)	0.0385	[0.144, 0.293]

※ 공식과 거의 같습니다. 공식이 없는 추정량(중앙값, disparate impact ratio 등)의 SE도 같은 코드로 구할 수 있다는 것이 bootstrap의 힘입니다. 노트의 “시뮬레이션으로 표본분포 근사”와 같은 생각입니다. [Notes §7.3]

9.3 좋은 추정량의 기준

기준	정의	뜻
Bias	$\mathbb{E}[\hat{\theta}] - \theta$ [Notes Def 7.2]	평균적으로 과녁 중심을 맞추는가
Variance	$\text{Var}(\hat{\theta})$	얼마나 흩어지는가
Standard error	$\sqrt{\text{Var}(\hat{\theta})}$ 의 추정값	보고용 흔들림 크기
MSE	$\mathbb{E}[(\hat{\theta} - \theta)^2]$ [Notes Def 7.3]	전체 오차 = $\text{Var} + \text{bias}^2$ [Notes Prop 7.4]
Consistency	$n \rightarrow \infty$ 이면 $\hat{\theta} \rightarrow \theta$	데이터가 많으면 결국 맞힌다

※ 과녁 비유: bias = 화살 무리의 중심이 과녁 중심에서 벗어난 정도, variance = 화살 무리의 퍼짐. MSE는 둘 다 합친 것이라, 약간의 bias를 감수하고 분산을 크게 줄이면 MSE가 더 작아질 수도 있습니다 (Ridge 회귀의 원리).

예: 분산 추정량의 bias를 시뮬레이션으로 확인 [↑ 2장 자유도 보강]

$N(65, 11.66^2)$ 에서 $n = 5$ 짜리 표본을 10만 번 뽑아 두 분산 추정량의 평균을 냈습니다.

추정량	10만 번 평균	진짜 $\sigma^2 = 135.96$ 대비
$\frac{1}{n} \sum (x_i - \bar{x})^2$ (ddof=0)	108.4	약 $\frac{4}{5}$ (bias ≈ -27)
$\frac{1}{n-1} \sum (x_i - \bar{x})^2$ (ddof=1)	135.5	거의 같음 (unbiased)

※ 이론값 $\frac{n-1}{n} \sigma^2 = \frac{4}{5} \times 135.96 = 108.8$ 과 일치합니다. $n = 582$ 에서는 $\frac{581}{582}$ 라 무시할 만합니다.

예: $\bar{X}$ 의 MSE [Notes Ex 7.5]

$\mathbb{E}[\bar{X}] = \mu$ (unbiased), $\text{Var}(\bar{X}) = \sigma^2/n \Rightarrow \text{MSE} = \sigma^2/n \rightarrow 0$ (consistent). 표본을 4배로 늘리면 SE가 절반이 됩니다 ($\sqrt{n}$ 법칙).

추정 · 가설 · 검증

추정의 보고 형식: “점추정값 (SE)” 또는 “점추정값, 95% CI”. 숫자 하나만 보고하면 그것이 얼마나 믿을 만한지 알 수 없습니다.

예: “남성의 합격률이 21.8%p 높다 (SE 3.7%p, 95% CI 14.5–29.2%p).”

10 추정량 만들기: 적률법(MoM)과 최우추정(MLE)

[↑ 4장 점추정 보강] ※ “momentum”이 아니라 **moment**(적률)입니다. 물리학의 moment(모멘트)와 같은 단어로, 분포의 “무게중심”(1차), “관성”(2차)이라는 비유에서 왔습니다.

10.1 적률 (moment)

- k 차 **moment**: $\mathbb{E}[X^k]$. 1차 moment는 평균. [Notes Def 4.1]
- k 차 **empirical moment**: $M_k = \frac{1}{n} \sum X_i^k$. pandas로는 `(df.col**k).mean()`. [Notes Def 4.2]
- 분산은 1, 2차 moment로 표현됩니다: $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

10.2 MoM 절차

[Notes Def 4.3]

1. 모형을 정한다: $X_i \sim f(x; \theta)$, parameter가 k 개.
2. 이론 moment $\mathbb{E}[X], \mathbb{E}[X^2], \dots, \mathbb{E}[X^k]$ 을 θ 의 식으로 쓴다.
3. 이론 moment = 표본 moment로 놓는다 (k 개의 방정식).
4. θ 에 대해 푼다.

예 1. **Bernoulli** (합격 여부): $\mathbb{E}[Y] = p \Rightarrow \hat{p} = M_1 = \bar{Y}$. 4장의 `groupby().mean()`.

예 2. **Normal** (`test_score`) [Notes Ex 4.6]: parameter 2개 $\Rightarrow$ 방정식 2개.

$$\hat{\mu} = M_1 = 65.24, \quad \hat{\mu}^2 + \hat{\sigma}^2 = M_2 \Rightarrow \hat{\sigma}^2 = M_2 - M_1^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = 135.66.$$

※ MoM 분산은 n 으로 나눈 것 (2장 `ddof=0`)이라 약간의 bias가 있습니다.

예 3. **Exponential** (대기 시간 등) [Notes Ex 4.5]: $\mathbb{E}[X] = 1/\theta \Rightarrow \hat{\theta} = 1/\bar{X}$.

예 4. **Poisson** (`years_experience`를 샘플 자료로 보면): $\mathbb{E}[X] = \lambda, \text{Var}(X) = \lambda$.

```
e = df.years_experience
e.mean(), e.var()
```

4.455, 3.851

1차 moment로 풀면 $\hat{\lambda} = 4.455$, 2차 moment(분산)로 풀면 $\hat{\lambda} = 3.851$. 같은 MoM인데 답이 다릅니다.

※ 어떤 moment를 쓰느냐에 따라 MoM 답이 달라질 수 있다는 것이 MoM의 약점입니다 (보통 낮은 차수부터 씀). [Notes Remark 4.4]

※ 동시에 모형 점검 도구이기도 합니다: Poisson이면 평균 = 분산이어야 하는데 분산이 더 작으므로 (**underdispersion**) Poisson 모형이 딱 맞지는 않는다는 신호입니다.

10.3 MLE 절차

[Notes §6.2]

1. Likelihood $L(\theta) = \prod_i f(x_i; \theta)$: “ θ 일 때 지금 데이터가 나올 확률”.
2. 로그: $\ell(\theta) = \sum_i \log f(x_i; \theta)$ (곱 $\rightarrow$ 합).
3. $\ell'(\theta) = 0$ 을 푼다.
4. $\ell''(\theta) < 0$ 으로 최댓값 확인. (경계에서 최대일 수도 있음: `Uniform(0, \theta)` [Notes §6.5])

예. **Poisson**: $\ell(\lambda) = -n\lambda + (\sum x_i) \log \lambda + C, \ell' = -n + \sum x_i/\lambda = 0 \Rightarrow \hat{\lambda} = \bar{x} = 4.455$. 1차 MoM과 같습니다.

예. **Bernoulli**: $\hat{p} = k/n$ (이전 책 §4). 예. **Normal**: $\hat{\mu} = \bar{x}, \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ (MoM과 같음).

10.4 MoM vs MLE: 언제 무엇을

	MoM	MLE
필요한 것	moment 식만	분포 전체
계산	방정식 풀기 (보통 쉬움)	미분 또는 수치 최적화
답의 유일성	moment 선택에 따라 다를 수 있음	하나 (보통)
정확도	괜찮음	큰 표본에서 분산이 가장 작음
변환	–	$g(\hat{\theta})$ 도 MLE (invariance)
쓰이는 곳	OLS, 초기값, 빠른 계산	logistic 회귀, 대부분의 모형

※ 여러 단순한 모형 (Bernoulli, Poisson, Normal 평균)에서는 두 방법이 같은 답을 줍니다. 다른 경우에는 보통 MLE를 씁니다.

※ 회귀와의 연결 [[→ 13장에서 자세히](#)]: OLS의 normal equation $\frac{1}{n} \sum x_i(y_i - \hat{y}_i) = 0$ 은 moment 조건 $\mathbb{E}[X\varepsilon] = 0$ 의 표본 버전입니다 (MoM). 오차가 정규분포면 OLS는 MLE이기도 합니다. [[Notes Prop 11.17](#)]

추정 · 가설 · 검증

추정 → 검정의 연결: MLE는 큰 표본에서 근사적으로 정규분포 $\hat{\theta} \approx N(\theta, SE^2)$ 를 따릅니다. 그래서 거의 모든 검정통계량이 $\frac{\hat{\theta} - \theta_0}{SE} \approx N(0, 1)$ 꼴이 되고, 이것이 다음 두 장의 출발점입니다.

11 가설 세우기와 검증 설계

[↑ 5장 검정의 다섯 단계 보강]

11.1 가설 세우는 법

1. 질문을 **parameter**로 바꾼다: “여성이 불리한가?” $\rightarrow p_F$ 와 p_M 의 비교.
 2. H_0 는 “효과 없음” (등호): $H_0: p_M - p_F = 0$. 귀류법의 “가정”에 해당합니다.
 3. H_1 의 방향을 데이터 보기 전에 정한다:
 - 양측 $H_1: p_M \neq p_F$: 어느 쪽이든 차이를 찾을 때 (기본값).
 - 단측 $H_1: p_M > p_F$: 한쪽 방향만 의미 있을 때. 노트 Ex 10.4–10.5 (신약이 늘렸는가). [Notes Ex 10.4]
- ※ 단측 p-value는 양측의 절반이라 기각하기 쉽습니다. 그래서 데이터를 본 뒤 단측으로 바꾸는 것은 반칙입니다. 노트도 이 점을 경고합니다. [Notes §10.2]
4. α 를 미리 정한다 (보통 0.05).

11.2 기각 판단의 두 방법

	기각역 (critical region) [Notes Def 10.2]	p-value [Notes Def 10.3]
방법	$ z \geq 1.96$ 이면 기각	$p = P(Z \geq z_{\text{obs}}) \leq \alpha$ 이면 기각
장점	데이터를 보기 전에 기준이 정해 짐	어떤 α 에서 기각되는지 다 알려줌
예 ($z = 5.72$)	$5.72 > 1.96 \Rightarrow$ 기각	$p = 1.1 \times 10^{-8}$

※ 두 방법은 항상 같은 결론을 줍니다. 보고할 때는 p-value와 효과 크기를 함께 씁니다.

11.3 신뢰구간과 검정은 같은 동전의 양면

[Notes §9.3] 노트의 **pivot**: 분포가 θ 와 무관하게 완전히 알려진 양. 예: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$.

- pivot을 θ 에 대해 풀면 $\rightarrow$ 신뢰구간.
- pivot에 $\theta = \theta_0$ 를 넣으면 $\rightarrow$ 검정통계량.

그래서 “95% CI에 θ_0 가 없다” $\iff$ “ $\alpha = 0.05$ 양측검정에서 $H_0: \theta = \theta_0$ 기각”.

11.4 두 종류의 오류와 검정력

- **Type I error**: 참인 H_0 를 기각 (거짓 정보). 확률 $\leq \alpha$ 로 우리가 통제합니다. [Notes Def 10.1]
- **Type II error**: 거짓인 H_0 를 기각 못 함 (놓침). [Notes Def 10.9]
- **Power** = $1 - P(\text{Type II})$: 진짜 효과가 있을 때 찾아낼 확률. [Notes Def 10.10]

검정력을 키우는 것: 큰 표본 n , 큰 효과, 작은 잡음 σ , 큰 α , (정당한 경우) 단측검정.

```
from statsmodels.stats.power import NormalIndPower
from statsmodels.stats.proportion import proportion_effectsize
```

```

es = proportion_effectsize(0.27, 0.22)                                # 5%p 차이
NormalIndPower().power(es, nobs1=300, alpha=0.05)                    # 0.30
NormalIndPower().solve_power(es, power=0.8, alpha=0.05)              # 그룹당 1159명

```

해석: 그룹당 300명이면 22% vs 27% (5%p) 차이는 **70% 확률로 놓칩니다**. 실제 격차 21.8%p는 검정력이 거의 1이라 확실히 잡힙니다.

※ 그래서 Marketing 남성 61명처럼 작은 그룹에서 “유의하지 않음”이 나오면 “차이 없음”이 아니라 “검정력이 부족함”일 가능성이 큼니다 (5장 주의, 이전 책 Bayesian 장).

11.5 검증에서 흔한 실수

- **p-value 오해**: $P(\text{data} \mid H_0) \neq P(H_0 \mid \text{data})$. 노트도 Bayes 정리로 이 점을 보여 줍니다. [Notes §10.3]
- 통계적 유의성 $\neq$ 실질적 중요성: n 이 아주 크면 0.1%p 차이도 유의합니다. 효과 크기를 함께 보고합니다.
- 다중검정: 부서 $\times$ 학위 $\times$ 경력으로 20개 그룹을 검정하면 우연히 하나쯤 $p < 0.05$ 가 나옵니다. Bonferroni: 각 검정을 α/m 기준으로.
- **p-hacking**: 원하는 결과가 나올 때까지 변수, 그룹, 검정을 바꾸는 것. 분석 계획을 먼저 정하고, 바꿨다면 모두 보고합니다.
- 가정 무시: 각 검정은 독립성, 표본 크기 등의 가정이 있습니다 (다음 장).

12 검정 도구상자: 어떤 검정을 언제 쓰나

[↑ 5장의 z -test, χ^2 , t -test 보강]

12.1 고르는 법: 세 가지 질문

1. 결과 변수의 종류는? 수치 (평균 비교) / 범주 (비율·빈도 비교)
2. 그룹이 몇 개? 하나 (기준값과 비교) / 둘 / 셋 이상
3. 표본이 독립인가, 짝지어져 있는가? (같은 사람을 두 번 잴는가)

결과	비교	검정	scipy.stats / statsmodels
수치	1그룹 vs 기준값	① one-sample z (σ 알) / ② t	<code>ttest_1samp</code>
수치	2그룹, 독립	⑤ two-sample z , pooled t , Welch t	<code>ttest_ind(equal_var=...)</code>
수치	2번 측정, 짝	⑥ paired t	<code>ttest_rel</code>
수치	3그룹 이상	⑪ ANOVA F	<code>f_oneway</code>
수치	분산	⑩ χ^2 분산 검정/구간	<code>chi2.ppf</code>
0/1	1그룹 vs 기준값	③ one-sample 비율 z	<code>proportions_ztest</code>
0/1	2그룹	④ two-sample 비율 z	<code>proportions_ztest</code>
범주	1변수 vs 기대분포	⑦ χ^2 적합도	<code>chisquare</code>
범주×범주	교차표	⑧ χ^2 독립성	<code>chi2_contingency</code>
범주×범주	칸이 작음	⑨ Fisher exact	<code>fisher_exact</code>
아무거나	여러 변수 통제	⑫ 회귀 계수 t / F	<code>smf.ols(...).summary()</code>
아무거나	분포 가정 없이	⑬ permutation, bootstrap	직접 구현

※ 모든 검정이 같은 때대: (추정값 - H_0 값)/SE, 또는 (관측 - 기대)²/기대. 다른 것은 추정 대상과 H_0 에서의 분포 ($N(0, 1)$, t , χ^2 , F)뿐입니다.

① One-sample z -test: σ 를 알 때 평균

[Notes Ex 10.4–10.5]

- 언제: 모집단 SD σ 가 알려져 있을 때 (드물. 예: 시험 출제기관이 SD를 공표).
- 가설: $H_0: \mu = \mu_0$. 통계량: $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \stackrel{H_0}{\sim} N(0, 1)$.
- 예: “이 시험의 평균은 64점, SD 12점”이라고 공표되었다면, 우리 지원자는 평균과 다른가? $z = \frac{65.24 - 64}{12/\sqrt{582}} = 2.48$, $p = 0.013 \Rightarrow$ 기각. 우리 지원자 풀은 평균보다 약간 높습니다.

② One-sample t -test: σ 를 모를 때 평균

[Notes Ex 10.6, Thm 8.16]

- 언제: 대부분의 실제 상황 (σ 를 s 로 추정).
- 통계량: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \stackrel{H_0}{\sim} t(n-1)$. σ 를 추정한 대가로 꼬리가 두꺼운 t 분포를 씁니다.
- 코드: `st.ttest_1samp(d.test_score, 64) → t = 2.56, p = 0.011`.
- 가정: 독립, 정규 (또는 n 이 커서 CLT).

※ [↑ 3장 보강] n 이 크면 $t(n-1) \approx N(0, 1)$: $t_{581, 0.025} = 1.964$ vs $z_{0.025} = 1.960$. n 이 작을 때만 차이가 중요합니다 (예: $t_{9, 0.025} = 2.262$).

③ One-sample 비율 z -test

- 언제: 0/1 결과의 비율이 기준값과 다른가.
- 통계량: $z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$. SE에 H_0 의 p_0 를 씁니다.
- 예: “업계 평균 합격률 30%”와 다른가? $\hat{p} = 0.322$, $z = \frac{0.0217}{\sqrt{0.3 \cdot 0.7/600}} = 1.16$, $p = 0.25 \Rightarrow$ 기각 못 함.
- 가정: $np_0 \geq 10$, $n(1-p_0) \geq 10$ 정도 (정규근사가 맞으려면).

④ Two-sample 비율 z -test

[↑ 5장 예 1 보강] 5장에서 한 성별 합격률 비교 ($z = 5.72$). SE에 합친 비율 $\hat{p}$ 를 쓰는 이유: H_0 에서는 두 그룹의 p 가 같다고 가정하기 때문.

※ 신뢰구간을 만들 때는 H_0 를 가정하지 않으므로 그룹별 $\hat{p}$ 로 SE를 계산합니다 (4장의 0.0374 vs 검정의 0.0382).

⑤ Two-sample 평균: z / pooled t / Welch t

[Notes §10.5]

검정	가정	SE
two-sample z	σ_1, σ_2 를 알	$\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}$
pooled t	$\sigma_1 = \sigma_2$ (모름)	$s_p \sqrt{1/n_1 + 1/n_2}$, df $n_1 + n_2 - 2$
Welch t	분산이 달라도 됨	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$, df 근사

예 (점수, 남 vs 여): pooled $t = 1.099$ ($p = 0.272$, $s_p = 11.66$), Welch $t = 1.101$ ($p = 0.272$). 분산비 0.92로 비슷해서 거의 같습니다.

※ 분산이 크게 다르고 표본 크기도 다르면 pooled t 는 틀린 p-value를 줍니다. 그래서 기본은 Welch.

※ [→ 13장에서 자세히] pooled t -test는 `smf.ols("test_score ~ C(gender)")`의 성별 계수 t 와 정확히 같습니다 ($t = 1.0986$). 회귀가 t -test를 포함합니다.

⑥ Paired t -test: 같은 대상을 두 번 잴 때

[Notes §10.6]

- 언제: 같은 지원자의 교육 전/후 점수, 같은 이력서를 두 평가자가 채점 등. 우리 데이터에는 짝자료가 없어 가상의 예로 설명합니다.
- 방법: 차이 $d_i = \text{after}_i - \text{before}_i$ 를 만들고 d 에 one-sample t ($H_0: \mu_d = 0$).

before	60	55	70	65	58	72	63	68	59	66
after	64	57	73	66	62	75	63	71	60	70
d	4	2	3	1	4	3	0	3	1	4

$\bar{d} = 2.5$, $s_d = 1.43$, $t = \frac{2.5}{1.43/\sqrt{10}} = 5.51$, df 9, $p = 0.0004$. 그런데 같은 데이터에 Welch t (독립 가정)를 쓰면 $t = 0.97$, $p = 0.34$.

※ 사람마다 실력 차이(55-72점)가 크지만, 차이를 빼면 그 개인차가 상쇄되어 잡음이 크게 줄어듭니다. 짝 구조를 무시하면 진짜 효과를 놓칩니다.

`st.ttest_rel(after, before)`

⑦ χ^2 적합도 검정 (goodness of fit)

- 언제: 범주 하나의 분포가 기대한 비율과 맞는가.
- 통계량: $\chi^2 = \sum \frac{(O-E)^2}{E} \stackrel{H_0}{\sim} \chi^2(k-1)$ (k = 범주 수).
- 예 1: 지원자 성비가 50:50인가? $O = (313, 287)$, $E = (300, 300)$, $\chi^2 = 1.13$, $df = 1$, $p = 0.29 \Rightarrow$ 기각 못 함.
- 예 2: 학위 분포가 “학사 50%, 석사 40%, 박사 10%”와 맞는가? $O = (311, 231, 58)$, $E = (300, 240, 60)$, $\chi^2 = 0.81$, $df = 2$, $p = 0.67$.
- 코드: `st.chisquare(observed, f_exp=expected)`

※ 자유도가 $k-1$ 인 이유: 기대빈도의 합이 n 으로 고정되어 있어서 $k-1$ 개만 자유롭습니다 (2장 자유도와 같은 논리).

⑧ χ^2 독립성 검정

[↑ 5장 예 2 보강]

- 언제: 두 범주 변수가 관련이 있는가 (교차표).
- 자유도: $(r-1)(c-1)$.
- 예 1 (성별 $\times$ 부서): $\chi^2 = 132.1$, $p \approx 10^{-30}$. 성별에 따라 지원 부서가 크게 다릅니다 $\rightarrow$ 부서가 confounder 후보라는 통계적 근거.
- 예 2 (학위 $\times$ 합격, 3×2): $\chi^2 = 8.32$, $df = 2$, $p = 0.016$. 학위와 합격은 관련 있음.
- 가정: 각 칸의 기대빈도 ≥ 5 . 아니면 ⑨.

※ χ^2 는 “관련이 있다”만 말합니다. 어느 방향인지, 얼마나 큰지는 비율표나 회귀로 봐야 합니다.

⑨ Fisher's exact test

- 언제: 2×2 표에서 기대빈도가 작을 때. 근사가 아니라 정확한 확률 (초기하분포)을 계산합니다.
- 예 (Marketing, 성별 $\times$ 합격; 남성 합격자가 6명뿐): Fisher $p = 0.169$. 기대빈도 최소 10.0이라 χ^2 도 쓸 수 있지만, 작은 셀에서는 Fisher가 안전합니다.
- 코드: `st.fisher_exact(pd.crosstab(mk.gender, mk.hired))`

⑩ 분산에 대한 χ^2 : 퍼짐의 추정과 검정

[Notes Ex 9.4, Thm 8.12]

- pivot: $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ (정규자료).
- σ^2 의 95% CI: $\left[\frac{(n-1)s^2}{\chi_{n-1,0.025}^2}, \frac{(n-1)s^2}{\chi_{n-1,0.975}^2} \right]$.
- 예 (test_score): $s^2 = 135.9 \Rightarrow \sigma^2 \in [121.5, 153.0]$, 즉 $\sigma \in [11.0, 12.4]$. “시험 SD가 12점”이라는 가설은 구간 안에 있으므로 기각하지 않습니다.

※ χ^2 는 대칭이 아니라서 구간이 s^2 를 중심으로 대칭이 아닙니다. 위쪽 분위수와 아래쪽 분위수를 따로 구합니다
(`chi2.ppf(0.975, n-1)`, `chi2.ppf(0.025, n-1)`).

⑪ ANOVA (F -test): 세 그룹 이상의 평균

- 언제: 학위 3종의 평균 점수가 같은가.
- 아이디어: $F = \frac{\text{그룹 간 분산}}{\text{그룹 내 분산}}$. 그룹 평균끼리의 차이가 그룹 안의 잡음보다 크면 F 가 큼.
- 예: 평균 점수 학사 65.4, 석사 64.8, 박사 66.0. $F = 0.32$, $p = 0.73 \Rightarrow$ 학위별 점수 차이 없음.
- 코드: `st.f_oneway(*[g.test_score for _, g in d.groupby("degree")])`

※ 왜 t -test를 세 번(학사-석사, 학사-박사, 석사-박사) 하지 않나? 다중검정으로 Type I 오류가 커지기 때문입니다. F 로 한번에 검정하고, 기각되면 그때 쌍별 비교를 합니다.

⑫ 회귀 계수의 t -test와 F -test

[→ 13장에서 자세히]

- 계수 하나: $H_0: \beta_j = 0$, $t = \hat{\beta}_j / \text{SE}$. “다른 변수를 통제했을 때 x_j 의 효과가 있는가.”
- 여러 계수 동시에: $H_0: \beta_{\text{Master}} = \beta_{\text{PhD}} = 0$ (“학위는 효과 없음”). `fit.f_test("C(degree)[T.Master] = 0, C(degree)[T.PhD] = 0")` → $F = 3.52$, $p = 0.030$.

※ 범주가 3개 이상인 변수의 효과는 계수 하나씩이 아니라 F 로 한꺼번에 검정해야 합니다 (⑪과 같은 이유).

⑬ Permutation test와 bootstrap: 공식 없이

- **Permutation:** H_0 가 “성별과 합격은 무관”이면 성별 라벨을 섞어도 상관없어야 합니다. 라벨을 5000번 섞어 차이를 계산하고, 관측 차이 0.218보다 극단적인 비율을 p-value로 씁니다.

```
obs = h[g=="M"].mean() - h[g=="F"].mean()
perm = [ (lambda pg: h[pg=="M"].mean() - h[pg=="F"].mean()) (rng.permutation(g)) for _
in range(5000) ]
np.mean(np.abs(perm) >= abs(obs)) # 0.0 (p < 1/5000)
```

- **Bootstrap:** 9장. 신뢰구간용.

※ 가정이 거의 없고 어떤 통계량에도 쓸 수 있습니다. 공식 검정의 결과를 확인하는 용도로 좋습니다.

12.2 검정들 사이의 관계 (외우지 않아도 되는 이유)

검정 A	검정 B
$2 \times 2 \chi^2$ 독립성	= two-sample 비율 z 의 제곱 ($32.7 = 5.72^2$)
pooled t	= 회귀 $y \sim C(\text{group})$ 의 계수 t
ANOVA F	= 회귀 $y \sim C(\text{group})$ 의 전체 F
상관 r 검정	= 단순회귀 기울기 t (6장, 8장의 6.13)
paired t	= 차이 d 에 대한 one-sample t
$t(n-1)$	→ $N(0,1)$ ($n \rightarrow \infty$)
t^2	= $F(1, \text{df})$

결론: 대부분의 검정은 회귀의 특수한 경우입니다. 그래서 datathon에서는 회귀 하나로 대부분을 처리하고, 단순 검정은 직관적인 보조 자료로 씁니다.

13 다중회귀: 통제된 뒤의 효과를 추정하고 검증하기

[↑ 7-8장 단순회귀 보강]

13.1 단순회귀에서 다중회귀로

$$\text{hired}_i = \beta_0 + \beta_1 \text{Male}_i + \beta_2 \text{Mkt}_i + \beta_3 \text{Master}_i + \beta_4 \text{PhD}_i + \beta_5 \text{score}_i + \beta_6 \text{exp}_i + \varepsilon_i$$

```
f = smf.ols("hired ~ C(gender) + C(department) + C(degree) + test_score +
years_experience",
data=d).fit(cov_type="HC1")
f.summary()
```

항	계수	robust SE	해석 (다른 변수 고정)
Intercept	-0.453	0.103	모든 변수가 기준값/0일 때 (의미 약함)
Male	0.088	0.039	남성이면 +8.8%p
Marketing	-0.221	0.039	Marketing이면 -22.1%p
Master	0.084	0.038	학사 대비 +8.4%p
PhD	0.120	0.068	학사 대비 +12.0%p
test_score	0.0098	0.0015	1점당 +1.0%p
years_experience	0.034	0.009	1년당 +3.4%p

$R^2 = 0.195$, 전체 $F = 23.2$ ($p \approx 10^{-24}$).

13.2 계수 해석: “다른 변수를 고정하면”

- 단순회귀 (8장): 점수 1점당 +0.0099. 다중회귀: +0.0098. 거의 같은 이유: 점수는 다른 변수와 거의 무관 ($r = 0.008$, 학위별 점수 차이 없음 ⑩).
- 성별: 단순 (이전 책 m1) +0.216 → 다중 +0.088. 크게 줄어든 이유: 성별과 부서가 강하게 연관 (⑧ $\chi^2 = 132$)되어 있고, 부서가 합격에 큰 영향을 주기 때문 (**omitted variable bias**).

※ 원칙: 통제 변수를 추가해서 계수가 크게 변한다면, 그 변수가 x 와 y 둘 다와 관련된 confounder라는 신호입니다.

13.3 범주형 변수와 기준 범주

$C(\text{degree})$ 는 Bachelor를 기준으로 Master, PhD 두 개의 0/1 열을 만듭니다. 계수는 “기준 대비 차이”입니다. 기준을 바꾸려면 $C(\text{degree}, \text{Treatment}(\text{"Master"}))$.

※ 범주를 숫자 1, 2, 3으로 넣으면 “학사→석사”와 “석사→박사” 효과가 같다고 가정하게 됩니다.

13.4 회귀 모형의 가정과 점검

[Notes Def 11.1] [↑ 8장 잔차도 보강]

가정	점검	어긋나면
선형: $\mathbb{E}[Y] = \alpha + \beta x$	평균의 그래프, 잔차도의 곡선	변환, 다항식, logistic
등분산: $\text{Var}(Y_i) = \sigma^2$	잔차도의 부채꼴	robust SE (HC1)
무상관: $\text{cov}(Y_i, Y_j) = 0$	자료 수집 방식	군집 SE
(검정용) 정규 오차	잔차 Q-Q plot	큰 n 이면 CLT로 괜찮음

※ LPM은 등분산이 깨질 수밖에 없으므로 (8장) robust SE를 씁니다. 여기서 성별 SE: 보통 0.0396, robust 0.0386. 차이는 작지만 원칙상 robust를 보고합니다.

※ 노트의 정리: 정규 오차면 $\hat{\beta} \sim N(\beta, \sigma^2 / \sum(x_i - \bar{x})^2)$ 이고 $\text{RSS}/\sigma^2 \sim \chi^2(n-2)$, 서로 독립. 그래서 t 분포가 나옵니다.

[Notes Thm 11.18]

13.5 회귀에서의 추정 · 가설 · 검증 정리

질문	가설	도구
통제 후 성별 효과?	$H_0 : \beta_{\text{Male}} = 0$	계수 t : $0.088/0.039 = 2.28$, $p = 0.023$
학위가 효과 있나?	$H_0 : \beta_{\text{Master}} = \beta_{\text{PhD}} = 0$	$F = 3.52$, $p = 0.030$
모형 전체가 쓸모 있나?	H_0 : 모든 기울기 = 0	전체 $F = 23.2$
부서별 성별 효과가 다른가?	$H_0 : \beta_{\text{Male} \times \text{Mkt}} = 0$	interaction 계수 t (이전 책 m3)

95% CI: $0.088 \pm 1.96 \times 0.039 = [0.012, 0.164]$. “다른 조건이 같다면 남성의 합격 확률이 1–16%p 높다.”

13.6 예측과 예측구간

[Notes Prop 11.16] 새 지원자의 예측값 $\hat{Y} = \hat{\alpha} + \hat{\beta}x$ 의 불확실성은 두 가지입니다.

$$\underbrace{\text{Var}(\hat{Y}) = \sigma^2 \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right)}_{\text{직선 자체의 불확실성}}, \quad \underbrace{\mathbb{E}[(Y - \hat{Y})^2] = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right)}_{+ \text{개인의 잡음}}$$

※ x 가 평균에서 멀수록 불확실성이 커집니다 (extrapolation 경고의 수학적 근거). 평균 예측 (신뢰구간)보다 개인 예측 (예측구간)이 항상 넓습니다. `f.get_prediction(new).summary_frame()`

13.7 회귀를 넘어서

- 결과가 0/1이면 logistic regression (이전 책 §7): 확률이 $[0, 1]$ 안에 머물고, 계수는 odds ratio로 해석.
- 성별 효과가 부서마다 다르면 interaction (이전 책 §6.9).
- 작은 그룹이 많으면 Bayesian (이전 책 §8).

14 한 장 요약

추정 대상	추정량	SE	검정통계량 (H_0 : 0 또는 같음)
평균 μ	$\bar{x}$	$s/\sqrt{n}$	$t = \frac{\bar{x}-\mu_0}{s/\sqrt{n}}, \text{ df } n-1$
비율 p	$\hat{p}$	$\sqrt{\hat{p}(1-\hat{p})/n}$	$z = \frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)/n}}$
$p_1 - p_2$	$\hat{p}_1 - \hat{p}_2$	$\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$	z (합친 $\hat{p}$ 로 SE)
$\mu_1 - \mu_2$	$\bar{x}_1 - \bar{x}_2$	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$	Welch t
독립성	교차표	—	$\chi^2 = \sum \frac{(O-E)^2}{E}$
상관 ρ	r	—	$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}, \text{ df } n-2$
기울기 β	$r \text{SD}_y / \text{SD}_x$	$\hat{\sigma} / \sqrt{\sum (x_i - \bar{x})^2}$	$t = \hat{\beta} / \text{SE}, \text{ df } n-2$
분산 σ^2	s^2	—	$\frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2(n-1)$
짝 차이 μ_d	$\bar{d}$	$s_d/\sqrt{n}$	paired t , df $n-1$
범주 분포	빈도	—	χ^2 적합도, df $k-1$
3+ 그룹 평균	그룹 평균	—	ANOVA F

공통 구조: 추정값 $\pm (1.96 \text{ 또는 } t \text{ 값}) \times \text{SE} = \text{신뢰구간}$, $(\text{추정값} - \text{가설값}) / \text{SE} = \text{검정통계량}$.

15 연습 문제

- 경력 자료의 평균 4.46, 중앙값 4, 최빈값 4이다. 분포 모양에 대해 무엇을 말할 수 있는가? 경력을 “개월”로 바꾸면 세 값과 SD (1.96년)는 어떻게 되는가?
- 2, 4, 4, 4, 5, 5, 7, 9의 평균, 편차, 편차의 RMS(SD), 그리고 $n - 1$ 로 나눈 s 를 구하시오.
- test_score의 $Q_1 = 58$, $Q_3 = 73$ 이다. 이탈값 율타리를 구하고, 70점인 지원자가 이탈값인지 판정하시오.
- 정규근사를 써서 test_score가 (a) 60점 이하 (b) 상위 5%가 되는 점수를 구하시오. ($\bar{x} = 65.24$, $SD = 11.66$, $\Phi(0.45) = 0.674$, $z_{0.05} = 1.645$)
- 여성 합격률 $\hat{p}_F = 0.217$ ($n = 313$)의 95% 신뢰구간을 구하고, “전체 합격률 32%와 같다”는 가설을 검정하시오.
- $r = 0.247$ 이고 $SD_y = 0.468$ 일 때 RMSE를 구하시오. r 이 0.8이라면 어떻게 되는가?
- 점수가 평균보다 1 SD 낮은 지원자의 예측 합격률을 SD 단위로 구하시오. 이 사람이 실제로 합격했다면 “운이 좋았다”고 말할 수 있는가?
- “합격자의 평균 점수가 69.4점이니, 69.4점을 받으면 합격한다”는 주장의 오류를 회귀 효과로 설명하시오.

추정량 · MoM (9–10장)

- $X_1, \dots, X_n \sim \text{Exponential}(\theta)$, $E[X] = 1/\theta$. 자료 2, 1, 4, 3으로 θ 의 MoM 추정값을 구하시오. MLE도 같은가?
- 추정량 A 는 unbiased이고 분산 4, 추정량 B 는 bias 1이고 분산 2이다. MSE로 비교하면 어느 쪽이 나은가?

검정 고르기 (11–12장)

- 다음 각 질문에 맞는 검정과 H_0 를 쓰시오. (a) 부서별(2개) 합격률이 다른가 (b) 학위(3종)별 평균 경력이 다른가 (c) 같은 지원자에 대한 면접관 A, B의 점수가 다른가 (d) 지원자의 학위 분포가 작년 비율과 같은가 (e) 점수와 경력을 통제해도 부서 효과가 있는가
- 어떤 연구자가 양측검정 $p = 0.08$ 이 나오자 단측검정으로 바꿔 $p = 0.04$ 로 “유의하다”고 보고했다. 무엇이 문제인가?
- Marketing의 성별 비교 Fisher $p = 0.169$ 를 근거로 “Marketing에는 성차별이 없다”고 결론 내릴 수 있는가? 검정력 관점에서 답하시오.

16 풀이

1.

Answer. 평균 > 중앙값 = 최빈값이므로 오른쪽으로 약간 긴 꼬리 (경력이 많은 소수). 개월로 바꾸면 ($\times 12$) 평균 53.5, 중앙값 48, 최빈값 48, SD 23.5개월.

Justification. $y = ax$ 이면 중심 측도는 모두 a 배, SD는 $|a|$ 배. z -score는 변하지 않습니다.

2.

Answer. 평균 5. 편차 $-3, -1, -1, -1, 0, 0, 2, 4$ (합 0). 제곱합 $9 + 1 + 1 + 1 + 0 + 0 + 4 + 16 = 32$. $SD = \sqrt{32/8} = 2$, $s = \sqrt{32/7} \approx 2.14$.

3.

Answer. IQR = 15, 울타리 $[58 - 22.5, 73 + 22.5] = [35.5, 95.5]$. 70점은 안쪽이므로 이탈값이 아닙니다.

4.

Answer. (a) $z = (60 - 65.24)/11.66 = -0.45$, $\Phi(-0.45) = 1 - 0.674 = 0.326$, 약 33%. (b) $65.24 + 1.645 \times 11.66 = 84.4$ 점.

Justification. (a)는 대칭 $\Phi(-z) = 1 - \Phi(z)$ 사용. (b)는 역방향: 면적에서 z 로, z 에서 점수로 ($x = \bar{x} + z \text{ SD}$). 실제 95백분위는 85점.

5.

Answer. $SE = \sqrt{0.217 \times 0.783/313} = 0.0233$, $CI = 0.217 \pm 0.046 = [0.172, 0.263]$. 0.32가 구간 밖이므로 $H_0 : p_F = 0.32$ 를 기각합니다.

Justification. 검정통계량으로 하면 $z = (0.217 - 0.32)/\sqrt{0.32 \times 0.68/313} = -0.103/0.0264 = -3.9$, $p \approx 10^{-4}$.

6.

Answer. $\sqrt{1 - 0.061} \times 0.468 = 0.454$. $r = 0.8$ 이면 $\sqrt{1 - 0.64} \times 0.468 = 0.6 \times 0.468 = 0.281$.

Justification. $r = 0.8$ 이어도 오차가 40%만 줄어듭니다. $\sqrt{1 - r^2}$ 는 r 이 1에 아주 가까워져야 작아집니다.

7.

Answer. 예측값은 y 평균보다 0.247 SD 낮음: $0.325 - 0.247 \times 0.468 = 0.21$. 합격은 예측(21%)보다 좋은 결과지만 “드문 행운”이라고 할 정도는 아닙니다. 다섯 명 중 한 명꼴로 일어나는 일입니다.

8.

Answer. 69.4점은 합격자를 조건으로 본 점수의 평균 (x on y 회귀)입니다. 점수를 조건으로 합격을 예측하려면 반대 방향 회귀 (y on x)를 써야 하고, 69.4점의 예측 합격률은 $-0.322 + 0.0099 \times 69.4 = 0.37$ 에 불과합니다. 두 회귀선은 다르고 (기울기 곱 = r^2), r 이 작을수록 더 크게 다릅니다.

9.

Answer. $\bar{x} = 10/4 = 2.5$, $\hat{\theta}_{\text{MoM}} = 1/2.5 = 0.4$. MLE도 0.4.

Justification. MLE: $\ell(\theta) = n \log \theta - \theta \sum x_i$, $\ell' = n/\theta - \sum x_i = 0 \Rightarrow \hat{\theta} = n/\sum x_i = 1/\bar{x}$. [Notes Ex 4.5, §6]

10.

Answer. $MSE_A = 4 + 0 = 4$, $MSE_B = 2 + 1^2 = 3$. B 가 낮습니다.

Justification. unbiased가 항상 최선은 아닙니다. $MSE = \text{Var} + \text{bias}^2$. [Notes Prop 7.4]

11.

Answer. (a) two-sample 비율 z 또는 $2 \times 2 \chi^2$, $H_0 : p_{\text{Eng}} = p_{\text{Mkt}}$. (b) ANOVA F , $H_0 : \mu_B = \mu_M = \mu_P$. (c) paired t , $H_0 : \mu_{A-B} = 0$. (d) χ^2 적합도, H_0 : 올해 분포 = 작년 비율, $df = 2$. (e) 다중회귀 계수 t ,

$H_0 : \beta_{\text{Mkt}} = 0.$

12.

Answer. 데이터를 본 뒤 가설의 방향을 바꾸면 실제 Type I 오류율이 α 보다 커집니다. 단측 여부는 데이터를 보기 전에 정해야 합니다. [\[Notes §10.2\]](#)

13.

Answer. 결론 내릴 수 없습니다. $p > 0.05$ 는 “증거 부족”이고, 남성이 61명뿐이라 검정력이 낮습니다. 실제로 점추정은 -8.5% p (여성이 높음)로 작지 않습니다. 결과는 “불확실함”으로 보고하고, 효과 크기와 신뢰구간을 함께 제시해야 합니다.